CMAWSE Evidence Registry Phase 3.7: 样本单元去重与分母完整性修复报告 (DUPLICATE SAMPLE UNIT INTEGRITY REPAIR)

1. 修改文件

- src/cmawse/registry/validator.py
  - 在 _check_granularity_and_denominator 方法中加入严格双重等价性约束，强制断言 len(ids) == len(set(ids)) == denominator。
- tests/test_registry_sample_unit_integrity.py (新增)
  - 建立专门的样本单元 ID 唯一性与分母对账攻击测试套件，全面覆盖 UNIT_LEVEL 与 AGGREGATE 在重复 ID 注入下的边界行为。

2. 修复前漏洞机制

- 漏洞根因：原校验逻辑仅比对了集合去重后的基数与分母（len(set(ids)) == denominator），或者仅比对了原始数组长度（len(ids) == denominator）。
- 绕过路径：
  - 若仅比对集合基数：攻击者构造 sample_unit_ids=["SU-01", "SU-01"] 并声明 denominator=1，集合长度为 1 与分母相等，绕过校验；
  - 若仅比对数组长度：攻击者构造 sample_unit_ids=["SU-01", "SU-01"] 并声明 denominator=2，数组长度为 2 与分母相等，使得只有 1 个独立物理样本的实验被虚报为 2 个样本。

3. 修复后约束 (The Tripartite Equality Invariant)

在 src/cmawse/registry/validator.py 中固化不可违背的刚性三元等式：

$$\operatorname{len}(\text{sample_unit_ids}) \equiv \operatorname{len}(\operatorname{set}(\text{sample_unit_ids})) \equiv \text{denominator}$$

具体执行断言：

1. 唯一性检查：len(record.sample_unit_ids) == len(set(record.sample_unit_ids))，若存在任何重复 ID，立即抛出 DUPLICATE_SAMPLE_UNIT_ID 违例。
2. 分母严格对账：去重集合长度必须精确等于 record.result.denominator，否则抛出 AGGREGATE_DENOMINATOR_MISMATCH 违例。
3. UNIT_LEVEL 规则保持：强制要求 len(record.sample_unit_ids) == 1。

4. 新增攻击测试用例清单

在 tests/test_registry_sample_unit_integrity.py 中实现并验证：

1. test_attack_duplicate_id_denominator_dedup: ids=["SU-01", "SU-01"], denominator=1 \implies FAIL (DUPLICATE_SAMPLE_UNIT_ID)
2. test_attack_duplicate_id_denominator_raw_length: ids=["SU-01", "SU-01"], denominator=2 \implies FAIL (DUPLICATE_SAMPLE_UNIT_ID)
3. test_attack_duplicate_id_mixed: ids=["SU-01", "SU-02", "SU-01"], denominator=3 \implies FAIL (DUPLICATE_SAMPLE_UNIT_ID)
4. test_unit_level_duplicate_rejected: UNIT_LEVEL, ids=["SU-01", "SU-01"] \implies FAIL (UNIT_LEVEL_MUST_HAVE_EXACTLY_ONE_SAMPLE)
5. test_aggregate_valid_cases_pass: ids=["SU-01"], denominator=1 \implies PASS；ids=["SU-01", "SU-02"], denominator=2 \implies PASS
6. test_aggregate_mismatched_unique_ids_fail: ids=["SU-01", "SU-02"], denominator=1 \implies FAIL (AGGREGATE_DENOMINATOR_MISMATCH)

5. 全部测试结果统计与回归核对

– BEFORE (Phase 3.3 规范恢复后基线)：

  – test_registry_validator.py: 18 passed
  – test_registry_adversarial_fixtures.py: 31 passed
  – test_schema_conformance.py: 11 passed
  – 总计：60 passed, 0 failed

– AFTER (Phase 3.7 样本单元去重修复后)：

  – test_registry_validator.py: 18 passed
  – test_registry_adversarial_fixtures.py: 31 passed
  – test_schema_conformance.py: 11 passed
  – test_registry_sample_unit_integrity.py: 6 passed (新增)
  – 总计：66 passed in 0.46s (100% PASS)

– REGRESSION 状态：

  REGRESSION: PASS

6. 是否仍存在 Duplicate SampleUnit ID Bypass

否 (BLOCKED)。 重复 ID 在原始列表长度与集合基数比对阶段即被拦截，无法再通过伪造分母或折叠列表绕过校验。

7. 当前 Validator 的准确职责声明

CMAWSE Evidence Registry Validator 当前被严格界定为只读的“结构规范与有向溯源关系图检验器（Structural &
Provenance Graph Checker）”。

它保证：

- 所有输入对象符合 Schema v0.1 的 Pydantic 类型与封闭枚举定义；
- 数据层级拓扑构成严格有向无环图（DAG），无断裂外键引用；
- 样本单元无重复项且与统计分母精确一致；
- 证据链具备单向因果方向（Experiment -> Condition -> Trial -> SampleUnit -> Evidence -> Statistic -> Claim -> Summary）。

它明确不负责亦不具备：

- 数值真实性重算（如根据原始数据点重跑统计检验）；
- 外部物理载荷文件的一致性与哈希认证（Payload Authentication）；
- 自然语言主张（Claim Statement）的科学真理性与泛化合理性判定。

8. 系统安全与能力判定矩阵

STRUCTURAL_INTEGRITY: COMPLETE
REFERENCE_PROVENANCE_INTEGRITY: COMPLETE
NUMERICAL_RECOMPUTATION: ABSENT
PAYLOAD_AUTHENTICATION: ABSENT
SCIENTIFIC_TRUTH_VALIDATION: ABSENT