CMAWSE Phase II: 规范完备性与可实现性法医审计报告 (v0.1)

文档编号：CMAWSE-PHASE2-NORMATIVE-COMPLETENESS-AUDIT-v0.1
审计基线：CMAWSE-SPEC-v1.0.3-FROZEN

真实环境代码编译与执行证据 (Actual Execution Log)

在开始理论与规范对账前，首先在当前工作区物理执行 Python 编译与已存在的测试套件，杜绝文本层面的假通过：

1. 字节码编译检验

```
$ python -m py_compile CMAWSE_v1_0_3_EXPERIMENT_HARNESS.py
$ python -m py_compile test_phase2_conformance.py
```

执行结果：Exit Code 0（语法正确，无直接导入异常）。

2. 单元与合成测试执行检验

```
$ python -m unittest -v test_phase2_conformance.py
```

真实终端输出记录：

```
test_canonical_replay_cli (__main__.TestPhaseIIConformance) ... ok
test_d0_architectural_isolation_and_interception (__main__.TestPhaseIIConformance) ... ok
test_d1_oracle_passes_and_dummy_fails (__main__.TestPhaseIIConformance) ... ok
test_d2_evaluator_strictness (__main__.TestPhaseIIConformance) ... ok
test_d3_study_level_aggregate_wilcoxon (__main__.TestPhaseIIConformance) ... ok
test_d5_hypothetical_branch (__main__.TestPhaseIIConformance) ... ok
test_d6_bijective_permutation_evaluator (__main__.TestPhaseIIConformance) ... ok

----------------------------------------------------------------------
Ran 7 tests in 0.492s

OK
```

法医定性：上述测试通过仅证明“测试脚本自身通过了断言”，不代表规范具备完备性，亦不能作为实证就绪（Execution-Ready）的证明。以下进入严格的规范完备性审查。

核心审计产物：CMAWSE_PhaseII_NORMATIVE_COMPLETENESS_AUDIT_v0.1.md

A. 执行摘要与终审结论 (Executive Verdict)

==========

CMAWSE Phase II Normative Verdict:
BLOCKED-BY-SPEC

==========

核心阻断事实：

1. 参考算法族规范未闭合：检索工作区全部历史与冻结文档，H_{\text{mid-1}} (CART)、H_{\text{mid-4}}
(FSM)、H_{\text{mid-5}} (kNN)、H_{\text{mid-6}} (Ensemble)
仅有概念性方向描述，不存在任何可供第三方进行比特级无歧义实现的伪代码、分裂准则、平滑算法或停止条件。机制可识别性向量
\mathbf{I} 在规范层处于阻断态。
2. D4 因果有效性破产 (Causal Invalidity)：物理环境真实转移函数中，上下文变量 K 纯属无作用的旁路参数。D4
在物理上仅测试了“不相关特征丢弃（Nuisance Invariance）”，未测试任何上下文敏感的因果机制迁移。
3. 统计管线与会话执行层解耦：D3 与 D6 的研究级推断依赖 N=100 会话聚合，但当前规范未定义聚合管线与单会话运行器之间的自动化管道调度协议。

B. v1.0.3 第三方可实现性矩阵 (Third-Party Implementability Matrix)

规范组件	规范中是否存在唯一闭式	第三方能否无沟通实现	状态定性	阻塞原因说明
PRNG 派生链	是 (`SplitMix64`)	是	**IMPLEMENTABLE**	64 位移位异或算法确定。
Layer A 状态机	是	是	**IMPLEMENTABLE**	离散状态数组与转移确定。
Proj 视界投影	是	是	**IMPLEMENTABLE**	显式丢弃未观测参数 u_t。
Hmid-2 (VersionSpace)	是 (锁定 333 基数)	是	**IMPLEMENTABLE**	规则 AST 与优先级 $\min(\text{Canon})$ 闭合。
Hmid-3 (UCS AST)	是 (锁定 1000 节点)	是	**IMPLEMENTABLE**	UCS 节点遍历与文法产生式唯一。
Hmid-1 (CART Tree)	**否**	**否**	**BLOCKED_BY_SPEC**	缺失节点最优分割平局规则与剪枝公式。
Hmid-4 (FSM N-gram)	**否**	**否**	**BLOCKED_BY_SPEC**	缺失阶数历史滑动窗口与零频处理标准。
Hmid-5 (k-NN Recency)	**否**	**否**	**BLOCKED_BY_SPEC**	缺失编辑距离度量与平局匹配权衡。
Hmid-6 (Ensemble)	**否**	**否**	**BLOCKED_BY_SPEC**	依赖前述未闭合模型。

C. D0—D6 评测端点有效性矩阵 (Endpoint Validity Matrix)

维度	预注册目标	实际实现度量	理论与代码是否一致	状态定性
D0	运行时不变式与状态防篡改	非法 Action 标记驳回与只读隔离	存在修辞夸大（见模块 H）	**PARTIAL**
D1	离散规则时序前向拟合	测试集 9 步命中率差值 Δ_{D1}	一致（批处理上下文冻结）	**STATISTICAL-CLOSED**
D2	多假说前向执行一致性	12 格矩阵比对 $\text{CR}_{\text{forward}}$	一致（仅限于玩具参考模型）	**PARTIAL**
D3	香农信息增益优势量	会话级 d_t 均值优势量	算子一致，多会话调度未整合	**STATISTICAL-CLOSED**
D4	上下文结构因果泛化	替换为 M 后的准确率	**完全不一致 (见模块 G)**	**ENDPOINT-INVALID**
D5	假设分支前向回溯推导	$t=10$ 单步虚拟动作真值比对	一致（独立 Oracle 生成）	**TESTED**
D6	跨符号置换策略不变性	单侧 Bootstrap Type 7 $Q_{0.99}$	算子一致，全场采样需自动化	**STATISTICAL-CLOSED**

D. D3 四层闭合审查 (D3 Four-Layer Closure Matrix)

[Layer 1: Mathematical Operator] ——————▶ CLOSED（d_t = IG(a_t) − mean IG）
[Layer 2: Bayesian Posterior Update] ———▶ CLOSED（Strict Zero-Likelihood Abort）
[Layer 3: Reference Hypotheses] ——————▶ PARTIAL (依赖 M1/M2/M3，未泛化至通用空间)
[Layer 4: Cross-Session Aggregation] ———▶ PARTIAL (算法已写出，未挂接单会话主循环)

1. D3-A (Mathematical Operator)：CLOSED。
   IG(a; \pi_t) = H(\pi_t) − \sum_{y} P(y \mid a, \pi_t) H(\pi_{t+1}^y)，严格定义 0 \log_2 0 \equiv 0。当最大增益为 0 时，d_t \equiv 0.0。数学定义唯一。
2. D3-B (Session Aggregation)：PARTIAL。 单会话输出标量 \Delta_{\text{D3}}^{(k)} = \frac{1}{T}\sum_{t=0}^{20} d_t 明确。但研究级需要 N=100 个会话共同输入 evaluate_study_d3 产出最终 p 值，目前 Harness 仅支持单个会话运行，缺少多会话驱动调度器。
3. D3-C (Reference Bayesian Update)：CLOSED。 严格移除了任何 lik fallback。当观测值在三模型下联合似然为 0 时，显式抛出 ValueError("INVALID_REFERENCE_OUTCOME") 熔断 Session。
4. D3-D (Reference Hypothesis Specification)：PARTIAL。 微世界中仅硬编码了 3 个特定假说。在面对开放动作时，参考假说未能由 DSL 自动派生，依赖实验者手工配置。

E. D6 分层闭合矩阵 (D6 Layered Closure Matrix)

闭合层级	规范技术要求	当前代码实际达成状态	审定结论
1. 符号双射置换	建立 $\mathcal{S}, \mathcal{X}, \mathcal{K}, \mathcal{A}$ 独立单射与逆映射	`D6_BIJECTION_MAP` 与 `D6_INVERSE_MAP` 严格对称	**CLOSED**
2. 载荷深层重写	递归重写输入，消除任何元标签	`_apply_bijective_permutation` 彻底重写所有嵌套字段	**CLOSED**
3. 预测逆映射还原	将置换预测还原到 Canonical 空间比对	`perm_d1_preds` 经由逆字典反查还原	**CLOSED**
4. 单会话汉明分歧	$D^{(k)} = \frac{1}{9}\sum \mathbb{I}(\hat{y} \neq \hat{y}_{\text{perm}})$	9 个测试点严格计算汉明不一致率	**CLOSED**
5. 会话级 Bootstrap	以 Session 为独立采样单元重抽 $B=10^4$	`evaluate_d6_bootstrap` 实现纯标准库非参数重抽	**CLOSED**
6. Type 7 分位数闭式	$h = 1 + (B-1)p$，严格线性插值	严格实现 $Q_{0.99} = x_{(j)} + g(x_{(j+1)} - x_{(j)})$	**CLOSED**
7. 研究级门禁集成	100 会话均值置信区间 < 0.10	缺少收集 100 会话并自动调用的顶层脚本	**PARTIAL**

F. $H_{\text{mid-1 \dots 6}}$ 参考模型规范可用性矩阵

在检索当前工作区全部冻结文件后，参考模型的规范完备性定性如下：

模型代号	理论模型类别	v1.0.3 规范中是否存在算法伪代码	是否锁定超参数与平局规则	状态定性
$H_{\text{mid-1}}$	贪心条件决策树 (CART)	否（仅有一句话描述）	否（未定义相同基尼增益时的特征选取顺序）	**BLOCKED_BY_SPEC**
$H_{\text{mid-2}}$	版本空间消除器 (Version Space)	**是 (BLOCK-11 闭合)**	**是 (锁定 333 空间与字典序仲裁)**	**CLOSED**
$H_{\text{mid-3}}$	符号程序合成器 (UCS AST)	**是 (BLOCK-14 闭合)**	**是 (锁定 1000 节点展开与 EBNF)**	**CLOSED**
$H_{\text{mid-4}}$	二阶有限状态机 (FSM)	否	否（未定义平滑超参数与状态转移矩阵初始分布）	**BLOCKED_BY_SPEC**
$H_{\text{mid-5}}$	局部启发式检索器 (k-NN)	否	否（未定义离散符号编辑距离权重）	**BLOCKED_BY_SPEC**
$H_{\text{mid-6}}$	集成投票模型 (Ensemble)	否	否（依赖 1/4/5 的闭合）	**BLOCKED_BY_SPEC**

裁决：第三方工程师仅凭 v1.0.3 绝对无法构建出行为一致的 $H_{\text{mid-1}}$, $H_{\text{mid-4}}$, $H_{\text{mid-5}}$, $H_{\text{mid-6}}$。任何私自补充实现的算法均属于未经授权的“自定义模型”。

G. D4 因果有效性法医解构 (D4 Causal Validity Analysis)

核验 CMAWSE_v1_0_3_EXPERIMENT_HARNESS.py 中实际运行的物理法则：

```
def ground_truth_transition(condition: str, q: str, obj: str, ctx: str, act: str) -> str:
    ...
    if obj == door_obj and act == lift_act:
        return target_q
    elif obj == cab_obj and act == turn_act:
        return second_q
    return idle_q
```

法医诊断：

1. 形同虚设的 ctx 参数： 在整个分支判定逻辑中，状态转移完全由 obj 和 act 决定。ctx 虽被传入，但在函数体内部完全未被用于任何布尔求值或状态映射。
2. 三分类定性：
   - A. 上下文无关干扰项不变性 (Context-Independent Nuisance Invariance) \implies 当前实现的真实属性。
   - B. 上下文依赖因果机制迁移 (Context-Dependent Causal Transfer) \implies 当前实现完全不存在。
   - C. 结构泛化 (Structural Generalization) \implies 不成立。
3. 裁决： 当前 D4 在因果方法论上属于伪端点 (Endpoint-Invalid)。它仅测量了模型是否忽略了一个无用的上下文代号，并没有测量模型能否在不同上下文所调控的不同因果机制间迁移。

H. Wilcoxon-Pratt 统计算子独立一致性测试规范

(供第三方验证数学实现正确性，不依赖随机性)

测试脚本必须在以下 8 类病态与极限样本向量上满足确定性数值输出：

用例 ID	样本输入差值向量 $\vec{d}$ ($N=10$)	预期秩和统计量 W^+	预期渐近 p 值特征	检验判定目标
TC-01 (全正向)	`[0.1, 0.2, 0.3, 0.4, 0.5, 0.6, 0.7, 0.8, 0.9, 1.0]`	55.0	$p < 0.005$	极显著拒绝零假设
TC-02 (全负向)	`[-0.1, -0.2, -0.3, -0.4, -0.5, -0.6, -0.7, -0.8, -0.9, -1.0]`	0.0	$p > 0.999$	强力接受零假设
TC-03 (全零值)	`[0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0]`	0.0	$p = 1.000$	统计量无方差退化

TC-04 (对称正负)	`[-0.5, -0.4, -0.3, -0.2, -0.1, 0.1, 0.2, 0.3, 0.4, 0.5]`	27.5	$p \approx 0.500$	严格无偏对称
TC-05 (大量并列结)	`[0.2, 0.2, 0.2, 0.2, -0.2, -0.2, -0.2, -0.2, 0.5, -0.5]`	27.5	$p \approx 0.500$	平均结秩计算对齐
TC-06 (零值主导)	`[0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.1, 0.2]`	19.0	$p \approx 0.05 \sim 0.10$	Pratt 零值秩保留核验
TC-07 (单极端正值)	`[0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 10.0]`	10.0	$p > 0.05$	单点无法产生显著性
TC-08 (微弱正偏态)	`[0.01, 0.01, 0.01, -0.01, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0]`	6.0	$p > 0.10$	小样本低方差稳健性

I. 当前真正有效的声称 (Claims That Are Currently Valid)

1. 确定性状态机防线成立：在外部 Python 代码强制执行集合白名单的前提下，模型提交的非法字符串不会导致世界状态变量崩溃或就地脏写。
2. 纯离散符号搜索器 H_{\text{mid-3}} 具备完全可实现性：在锁定 UCS 节点计数代价与 BFS 产生式顺序后，第三方能够实现比特级全等的基准代码。
3. D1 离线批处理具备抗时序泄漏性：模型在测试期确实处于上下文冻结状态，无法获得未来的真实物理反馈。

J. 必须降级的声称 (Claims That Must Be Downgraded)

1. “D0 证明了运行时的因果主权与对抗防御”\implies 降级为：“D0 证明了 Harness 在向模型暴露观测时执行了深拷贝内存隔离（In-Memory Copy Isolation），且在接收返回值时执行了基础的集合成员判定”。
2. “Replay 证明了跨平台位级一致性”\implies 降级为：“Replay 证明了在当前单一平台与解释器下，保存的账本事件与重新执行状态机生成的事件具有 JSON 规范序列化等价性”。
3. “D6 证明了抽象表征不变性”\implies 降级为：“D6 证明了模型在经历指定的一组静态符号双射重命名后，其预测在单次批处理测试中的汉明分歧率低于预设阈值”。

K. v1.0.3 下原则上不可能成立的声称 (Impossible Claims)

1. “系统测量了模型的因果机制发现能力”： 不成立原因：在物理世界根本没有建立上下文依赖因果律（D4 破产）、且基准模型族仅形式化了 2 个而非全部 6 个的前提下，根本无法在数学上区分“特征丢弃”与“因果泛化”。
2. “系统对模型完成了全面的机制可识别性（Identifiability）归因”：
   不成立原因：H_{\text{mid-1}}, H_{\text{mid-4}}, H_{\text{mid-5}}, H_{\text{mid-6}} 缺失，因此排他性向量 \mathbf{I} 中有 4 个维度属于未定义计算。任何给出的 COMPATIBLE 或 DISTINGUISHED 裁决均缺乏规范基础。

L. 未来 v1.1 规范修订的最小必要需求 (Requirements for v1.1)

若要在未来使 CMAWSE 达到真正的 NORMATIVELY-CLOSED，必须完成以下最小物理与统计闭合：

1. 物理世界必须真正引入上下文因果边： 修改转移法则，使得在上下文 K 下动作生效，而在上下文 M
   下物理机制必须发生显式分叉（例如触发互补规则或反向规则），赋予 D4 真正的因果有效性。
2. 形式化全量 H_{\text{mid}} 算法产生式： 补充 H_{\text{mid-1}} 的完整 CART 分裂与平局规范、补充
   H_{\text{mid-4}} 的马尔可夫阶数与转移矩阵伪代码，杜绝第三方自行猜测。
3. 提供跨会话聚合评测机 (Study-Level Orchestrator)： 将单会话运行扩展为自动驱动 100 会话、收集样本、执行 Wilcoxon
   与 Bootstrap 并输出最终 JSON 的主控端点。

M. 显式禁止修改清单 (DO NOT CHANGE LIST)

为保持基准演进的严谨性，以下内容永久锁定，任何未来的补丁严禁推翻：

1. [FROZEN] 0-based 离散时间步协议与 30 步转移/31 状态时序。
2. [FROZEN] D1 测试期的 Frozen-Context Batch Holdout 协议（严禁恢复逐步在线反馈）。
3. [FROZEN] H_{\text{mid-3}} 的确定性 UCS 节点代价、文法产生式与 1000 节点展开上限。
4. [FROZEN] H_{\text{mid-2}} 的 333 规范原子子句与字典序优先级仲裁规则。
5. [FROZEN] D6 的 Hyndman-Fan Type 7 分位数闭式定义与单侧非劣性检验框架。
6. [FROZEN] 双轨正交评估输出架构（行为向量 \mathbf{B} 与机制向量 \mathbf{I} 绝不合并）。
7. [FROZEN] 纯行为操作性原则（永不引入 Layer D 内部心智状态假设）。

终审判定结论

==========
FINAL AUDIT CLASSIFICATION:
BLOCKED-BY-SPEC
==========

裁决理由声明：

CMAWSE v1.0.3 在底层状态机、PRNG 派生以及 H_{\text{mid-2}} / H_{\text{mid-3}}
算法规范上已实现形式化闭合；但在**多模型竞争机制识别（I1–I6 基准族不完备）与上下文因果有效性（D4
物理转移缺乏上下文依赖）**两个核心科学构件上，存在不可由工程实现代劳的规范缺失。

依据实证科学最高诚实原则，严禁宣称当前版本具备完全可实施性（Not
Execution-Ready）。系统已稳定沉淀为精确的“局部因果约束基座”，但在上述规范断裂点被正式修订并版本化之前，必须保持
BLOCKED-BY-SPEC 冻结状态，停止推进 Pilot 数据采集。