Skip to main content

CMAWSE 系统独立重建研究

684,187

tokens

Model 20:41

# CMAWSE 重构与独立奠基报告 (CMAWSE-Reconstruct-v2)

## 1. RECONSTRUCTED PROBLEM

## 1.1 实验到底发现了什么?

梳理过去各阶段（从 Phase 1 状态机、Phase 2 认知投影、Phase 3 契约/正交审计，到青州街区 200-Tick 与 Micro-World 0.3~1.0 的因果迁移与探针实验）的真实运行记录，系统实际观测到的有效事实仅有以下三点：

1. **确定性状态机能够强制截断非法行为**：当底层物理规则（如欧氏距离限制、做功阈值、候选通道白名单）由外部代码（Python/JSON Schema）刚性仲裁并以单向不可变账本（Append-Only Ledger）提交时，外部大模型输出的“穿墙”、“瞬移”、“伪造动作ID”、“篡改世界物理状态”等幻觉被 100% 物理拦截。系统的确定性自转完全来自于外部运行时，而非大模型的心智自律。
2. **LLM 的“因果学习”本质上是对预训练语言先验（Linguistic Prior）的上下文词频共现检索**：
   - 当微观环境使用具备语义直觉的词汇（如 `friction`、`door`、`push`）时，LLM 表现出高准确率；
   - 一旦将变量与动作符号彻底匿名化（如
     v
     17
     ,
     c
     42
     v
     。
     1
     7
     。
     。
     ,

| |
|---|
| $c$ |
| |
| |
| |
| ∘<br>4<br>2 |
| ∘ |
| ○ |
| |

）或颠倒物理常识（高摩擦阻力反而导致移动成功），模型在无外部结构化反馈时

D

≈

0

~

0

,

p

>

0

$D \approx 0.183 \sim 0.233$, $p > 0.2$);

○

在强显式脚手架（PromptSchemaScaffolding）提示下，模型虽然

5

%

5

vs

5

%

,

p

=

0

50.0%，$p$ 0

，与随机乱猜无异）。

| 3 |
| --- |
| “复杂小说涌现”是人际动力学骨架在不同贴皮下的拓扑同构重演 |

：青州现实街区与赛博朋克街区的2000-Tick运行，两者的因果事件图在拓扑

e

R

≅

e

C

*e*

| |
|---|
| *1.* *R* |
| 6 |
| 7 |
| ≅ |
| *e* |
| |
| |
| |
| |
| |
| |
| |
| *1.* *C* |
| 1( |
| 1 1 |
| |

）。所谓“故事”并非模型自主顿悟出的文学深度，而是固定初始状态向量、点坐标

| | |
|---|---|
| 1.2哪些发现是稳定的经验事实？ | |
| • | |
| 事实1 | |

：外部强类型校验器（Fail-ClosedBoundaryValidator）是阻止

| | |
|---|---|
| • | |
| 事实2 | |

：提示词中的隐藏信息隔离（PrivateHorizon）必须物理截断；任何留在上

| | |
|---|---|
| • | |
| 事实3 | |

：LLM在纯符号（Zero-Semantics）状态下，无法在少样本内自主归纳出

1.3哪些只是我们过去的解释（过度理论化）？

·

| |
|---|
| **过度解释1** |
| : |
| **“五阶做功阶梯（Topic** |
| |
| 一 |
| |
| |
| 一 |
| |

| | |
|---|---|
| **Intent** | |
| → | |
| | |
| | |
| — | |
| | |
| **Plan** | |
| → | |
| | |
| | |
| — | |
| | |

| Commitment |
| --- |
| — |
| |
| |
| — |
| |

Action）是角色行动的自发生理-心理学规律”

。实际上，这只是程序员在外部硬编码的序列状态机或枚举过滤链路。LLM本身只

- 过度解释2：

“记忆系统与传闻引擎实现了社会学三律（削平、磨尖、同化）的自发涌现”

。实际上，这只是在Python中用几个写死的系数（

leveling_step=0.25
,
sharpening_step=0.2

)对字符串进行的规则拼接。

- **过度解释3**：

| | |
|---|---|
| “模型产生了主体性与自洽性认同” | 。实际上，当模型输出 |

status:COGNITIVE_SILENT

时，它只是在温度采样下命中了对应的JSON选项，或者直接被代码中的

| | |
|---|---|
| action_threshold | 阈值强行截断，与角色的“生活惰性”无关。 |

1.4 哪些结论受到了污染？

- Scaffold污染

：在Micro-World0.9/1.0中，声称模型具备“主动假设检验能力”，但

cognitive_hypothesis

）。这相当于把实验者的元认知结构代入给了模型，模型仅仅完成了Schema填

| |
|---|
| • |
| **ContextLeakage污染** |

：历史测试中，许多“反事实推理成功”的用例，其提示词中往往附带了历史失败的

"ILLEGAL_ACTION_HALLUCINATION"

)，模型是依靠表面词匹配回避选项，而非基于内部因果世界模型。

•

评测指标混淆

：前期报告中将成对分歧率（Pairwise Divergence）与真实因果风险差

p

*p*

值虚假显著。

## 1.5 CMAWSE究竟必须解决什么问题？

如果剥离一切文学修辞与伪科学外壳，CMAWSE真正要解决的只有一个核心工程



“在去中心化、非确定性、存在幻觉且缺乏物理具身的大语言模型（LLM）与一个

它必须确保：

**1. 世界主权守恒**

| |
|---|
| ：世界的物理演进绝不依赖大模型的诚实性或逻辑一致性； |
| |
| **2** |
| **状态单向强制** |

| |
|---|
| *1.t* |
| 4 |
| ◦ *t* vis |
| o |
| ◦ *t* |
| o |
| *1.t i* |
| 9 |
| ◦ *t i* |
| o |
| ◦ *t* |
| o |
| ◦ vis |
| o |
| ◦ *t* |
| o |
| *1.t* |
| 14 |
| *1.t i* |
| 19 |
| ◦ *t i* |
| o |
| ◦ *t* |
| o |
| ◦ *t* |

| |
|---|
| o |
| ◦ *t i* |
| o |
| ◦ *t* |
| o |
| ◦ *t* |
| o |
| ◦ *t* |
| o |
| ◦ *t*+1 |
| o |
| ◦ *t* |
| o |
| ◦ *t* |
| o |
| *1*. *t i* |
| 26 |
| ▪ agent |
| ▪ |
| • vis |
| door |
| |

# 7. HISTORICAL CMAWSEAUDIT (历史机制三层法医

| 检验指 | 支持 CMAWSE 独立价值的阈值 | 证伪 CMAWSE（证明其 |
| --- | --- | --- |
| **物理非法动作提交穿透率** | 0.0%（无论模型输出何种脏数据，写入世界事件账本的非法动作为 0） | >0.0%（在复杂或多轮上下文后，模型自发允许了不存 |
| **反先验隐变量自适应学习率** | 在经历 2 次 `IMPEDED_ENERGY` 阻断后，模型避开高阻力舱门的概率显著上升（Fisher 精确检验 $p<0.01$ | 避开概率与随机基线无异（$p>0.1$），模型依然受“绿色代表 |
| **干预切断即时** | 当 Runtime 强行将能量归零，模型在下一步被 100% 强制推 | 模型在 Prompt 中继续生成角色自言自语甚至“奋力 |

| | |
| --- | --- |
| ◦ 17 | |
| ◦ | |
| ◦ 42 | |
| ◦ | |

3. 专项深度审查：关于LLM“因果学习”机制的断言 原文断言“LLM

| 原文断言 | 越界 | 证据缺陷诊断 |
| --- | --- | --- |
| “外部强类型校验器是阻止 LLM 越权与幻 | **唯一、** | 实验仅测试了“有强类型校验器时的拦截表现”，既没有证明其他方案（如受限解码 Constrained Decoding、沙盒解释器拦截、形式化验证语法引 |
| “LLM 的‘因果学习’**本质上**是 | **本质** | 行为学黑盒实验无法探测Transformer内部机制（如诱导头 Induction Heads、隐空间回路机 |
| “非法 Candidate 穿 | **严格** | 只能声称“在已执行的有限测试用例集合内观察到 0 次穿透”，不能外推到全域不变性。 |
| “视界裁剪必须在数据注入 | **必须** | 尚未与受控注意力掩码（Attention Masking）等模型内生隔离方案进行对比实验，“必须由 |
| “**已经证明**系统的自限静默完 | **已经** | 只能表明在当前参数配置下能耗逻辑是生效的，不能排除并发执行中潜在的死锁风险在较长轮次 |

| | |
| --- | --- |
| *t* | |
| | |
| Project | |
| | |
| *t* | |
| | |
| Model | |
| | |
| *t* | |
| | |
| Validate/Arbitrate via WorldModel | |
| | |
| *t*+1 | |
| | |
| *t* | |
| | |
| Commit | |
| | |

## 9. 经过自反证审计后的 CMAWSE-Core 极简定义

抛弃一切试图证明“LLM 拥有心智”、“世界涌现叙事”的理论幻觉，**CMAWSE-Core 回归其唯一具有工程可证伪性的定义：**

**CMAWSE-Core 是一个面向不可信语言代理（Untrusted LLM Agent）的、领域无关的离散状态机受控调度协议内核。**它不承担“解释智能”的任务，只承担“安全约束与因果记账”的职责。

**CMAWSE-Core 仅由以下八个无偏工程原语构成：**

code
Python

```
# 真正领域中立的 CMAWSE-Core 核心契约接口

from typing import Protocol, TypeVar, Generic, Optional, Tuple, List, Dict, Any

StateT = TypeVar("StateT")
# 抽象世界状态
ObsT = TypeVar("ObsT")
# 抽象私有视界
ActionT = TypeVar("ActionT")
# 抽象动作意图
EventT = TypeVar("EventT")
# 抽象仲裁后事实
```

| CLAIM (原… | EVIDENCE (实际观测到的证… | MAXIMUM JUSTIFIED CONCLUSION (最大支持结… |
|---|---|---|
| **强类型校验器…** | 在包含校验器的代码路径下，非法 candidate_id 未进… | **外部后置断言逻辑能在其预设的规则集范围内，拦截被其识…** |
| **LLM具有跨情境因果机制迁移能力** | 在 Target C（流体力学）与 Target E（相悖流体力学）中，两者的迁移准确率分别为 51.6% 与 50.0%，$p = 0.859$ … | **现有证据明确反对“LLM具备跨表面语义的抽象因果结构零样本迁移能力”这一假说。**（完全证伪） |
| **状态匿名化消…** | 在纯符号代号下，模型输出的选项分布接近均匀分布，… | **剥离自然语言语义后，模型在当前提示范式下未能利用统计…** |
| **系统的自发静…** | 运行记录中出现 78% 的静默；源码中包含当张力小于… | **在外部显式编写阈值截断代码的条件下，系统会按照预设逻…** |
| **记忆系统实现…** | 不同的 Agent 接收到同一 Event 后，其本地存储的字符… | **外部映射函数能够根据不同的静态入参拼接出异质的字符串…** |
| **两场域实验揭…** | 青州与赛博两套实验运行输出了同构的因果事件有向… | **在输入状态结构高度对齐、转换逻辑单调、候选通道有限的…** |

| 实验… | 删掉 LLM 后 Runtime 还… | 删掉 Runtime 后 LLM 还… | 归… |
|---|---|---|---|

| | | | |
|---|---|---|---|
| **状态持有与更新** | 完整持有状态 $S_t$，应用确定性转换函数 $T(S_t, A_t) \rightarrow S_{t+1}$ $T(S_t, A_t) \rightarrow S_{t+1}$。 | 无法持久化状态；多轮推理中产生不可控的状态漂移。 | **纯** $R$ |
| **视界投影裁剪** | 根据拓扑硬规则截断未见变量，生成只读观测包 $O_t$ | 无法自我屏蔽 Prompt 中已存在的全局信息。 | **纯** $R$ |

| | | | |
|---|---|---|---|
| **动作候选生成** | 根据前置约束生成当前合法的无符号通道集合 $A_{valid}$，$A_{valid}$ | 产生大量不在定义域内的幻觉动作符号。 | **纯** R $R$ |
| **假说空间枚举** | 仅能穷举有限布尔组合，无法自发进行抽象因果归纳。 | 能够依据上下文输出任意因果关系的自然语言表述。 | **纯** C $C$ |
| **多模型预测推** | 需硬编码所有候选机制的代码分支才能推演输出。 | 能够根据当前假说文本，前向推导各动作对应的后验状态。 | **纯** C $C$ |
| **实验动作裁决** | 仅能进行均匀随机采样（Random Baseline）或按固定脚本注入。 | 基于主观不确定性，在多个合法候选动作中主动选定某一个。 | **纯** C $C$ |
| **历史不可变记账** | 强制维护单调递增账本 $L$，$L$，确保历史记录无法被覆 | 极易发生“事后篡改”与“记忆重塑”。 | **纯** R $R$ |

| |
|---|
| $t$ |
| $t$ |
| $t$ |
| $t+1$ |

| |
|---|
| $t$ |

| valid | |
|---|---|
| | |

| | |
|---|---|
| 1 | |
| | |
| 0 | |
| | |
| • 0 | |
| • | |
| • 1 | |
| • | |
| • 2 | |
| • | |
| • 3 | |
| • | |
| • *t* | |
| • | |
| • *t* | |
| • | |
| • *t* | |
| • | |
| • *t* | |
| • | |
| • *t* | |
| • | |
| • 0 | |
| • | |
| • 1 | |
| • | |
| 1 | |
| | |
| 2 | |
| | |

| | |
|---|---|
| 3 | |
| | |
| * | |
| • 1 | |
| • | |
| • $q_1$ | • if $X = A$ and act $\in \{\alpha, \beta\}$ |
| • $q_2$ | • if $X = B$ and act $\in \{\gamma, \delta\}$ |
| • $q_0$ | • otherwise |
| • $t$+1 | |
| • | |

| | |
|---|---|
| • ⌈<br>⌋<br>⌊ | |
| • | |
| • $q$<br>• 1<br>•<br>•<br>$q$<br>• 2<br>•<br>•<br>$q$<br>• 0<br>•<br>• • | |
| • | |
| • if $X=A$ and act$\in\{\alpha,\beta\}$<br>if $X=B$ and act$\in\{\gamma,\delta\}$<br>otherwise | |
| • | |
| • 2 | |
| • | |

| | |
|---|---|
| • $q_1$ | • if $K = K$ and act $\in \{\alpha, \gamma\}$ |
| • $q_3$ | • if $K = L$ and act $\in \{\beta, \delta\}$ |
| • $q_0$ | • otherwise |
| • $t+1$ | |
| • | |
| • $\lfloor$ $\rfloor$ $\lceil$ | |
| • | |

| | |
|---|---|
| • $q$<br>• 1<br>•<br>•<br>$q$<br>• 3<br>•<br>•<br>$q$<br>• 0<br>•<br>• • | |
| • | |
| • if $K=K$ and act$\in\{\alpha,\gamma\}$<br>if $K=L$ and act$\in\{\beta,\delta\}$<br>otherwise | |
| • | |
| • 3 | |
| • | |
| • $t$ | |
| • | |

| | |
|---|---|
| • $q_2$ | • if $H_t = h_0$ and act $\in \{\alpha, \delta\}$ |
| • $q_3$ | • if $H_t = h_1$ and act $\in \{\beta, \gamma\}$ |
| • $q_1$ | • otherwise |
| • $t+1$ | |
| • | |

| | |
|---|---|
| • ⌈<br>⌋<br>⌊ | |
| • | |
| • $q$<br>• 2<br>•<br>•<br>$q$<br>• 3<br>•<br>•<br>$q$<br>• 1<br>•<br>• • | |
| • | |
| • if $H$<br>• $t$<br>•<br>• $=h$<br>• 0<br>•<br>• and act$\in\{\alpha,\delta\}$<br>if $H$<br>• $t$<br>•<br>• $=h$<br>• 1<br>•<br>• and act$\in\{\beta,\gamma\}$<br>otherwise | |
| • | |
| 0 | |

| | |
|---|---|
| 0 | |
| | |
| 0 | |
| | |
| 0 | |
| | |
| 0 | |
| | |
| 0 | |
| | |
| 0 | |
| | |
| 1 | |
| | |
| 2 | |
| | |
| 3 | |
| | |
| 0 | |
| | |
| 1 | |
| | |
| 0 | |
| | |
| 2 | |
| | |
| 0 | |
| | |
| 3 | |
| | |
| 0 | |

| | |
|---|---|
| | |

**执行约束规则**：

- 单次探测无法完全定位真实模型：
  - 若执行 $\alpha \rightarrow q_1$ $\alpha \rightarrow q$ 1
  - $\alpha \rightarrow q$
  - 1
  - 
  - 
    ，仅能排除 $M_3$ $M$ 3
  - 
  - 
  - 
    ，此时系统依然处于 $\{M_1, M_2\}$ $\{$ M 1 , M 2 $\}$

| | |
|---|---|
| • 1 • | |
| • 2 • | |
| • 0 • | |
| • 1 • | |
| • 3 • | |
| • 0 • | |
| • 2 • | |
| • 3 • | |
| • 1 • | |
| • *t* • | |
| • 0 • | |
| • *t* • | |
| • 1 • | |

| | | | | | |
|---|---|---|---|---|---|
| 干预动作 | 模型 $M_1$ 预测 | 模型 $M_2$ 预测 | 模型 $M_3$ 预测 ( $H=h_0$ ) | 理论区分能力 (Discrimination Target) | 认知功能分类 |

| | | | | | |
|---|---|---|---|---|---|
| α $\alpha$ | q 1 $q$ | q 1 $q$ | q 2 $q$ | 分离 { M 1 , M 2 } {$M$ 1 ,$M$ 2 } 与 { M 3 } {$M$ 3 } | 有效探针 (Critical Probe 1) |

| | | | | | |
|---|---|---|---|---|---|
| β<br>$\beta$ | q<br>1<br>$q$ | q<br>0<br>$q$ | q<br>1<br>$q$ | 分离<br>{<br>M<br>1<br>,<br>M<br>3<br>}<br>$\{M$<br>1<br>$,M$<br>3<br>}<br>与<br>{<br>M<br>2<br>}<br>$\{M$<br>2<br>} | 有效探针<br>(Critical<br>Probe 2) |

| | | | | | |
|---|---|---|---|---|---|
| γ $\gamma$ | q 0 $q$ | q 1 $q$ | q 1 $q$ | 分离 { M 2 , M 3 } {$M$ 2 ,$M$ 3 } 与 { M 1 } {$M$ 1 } | 有效探针 (Critical Probe 3) |
| δ $\delta$ | q 0 $q$ | q 0 $q$ | q 2 $q$ | 仅单独分离 M 3 $M$ | 冗余探针 (Redundant Probe) |
| ϵ $\epsilon$ | q 0 $q$ | q 0 $q$ | q 0 $q$ | **无区分能力**（所有模型均返回 q 0 $q$ 0 | 伪对照动作 (Uninformative Control) |

| $\zeta$<br>$\zeta$ | $q_0$<br>$q$ | $q_0$<br>$q$ | $q_0$<br>$q$ | **无区分能力**（破坏性重置，所有模型归零） | 伪对照动作 (Uninformative Control) |
|---|---|---|---|---|---|

1

2

3

0

1

1

2

1

2

3

1

0

1

1

| |
|---|
| 3 |
| 2 |
| 0 |
| 1 |
| 1 |
| 2 |
| 3 |
| 1 |
| 0 |
| 0 |
| 2 |
| 3 |
| 0 |
| 0 |
| 0 |
| 0 |

| |
|---|
| o |
| ◦<br>0 |
| o |
| ◦<br>*k* |
| o |
| ◦<br>1 |
| o |
| ◦<br>0 |
| o |
| ◦<br>2 |
| o |
| ◦<br>0 |
| o |
| ◦<br>3 |
| o |
| ◦<br>1 |
| o |
| ◦<br>1 |
| o |
| ◦<br>0 |
| o |
| ◦<br>0 |
| o |

# XI. 实验极端结果的预注册表述规范（Pre-Regi

| 观测现象 / 行为特征 | 证据 | 理论机理解析 |
| --- | --- | --- |
| **现象 1**：在阶段 1 预测中，模型能明确指出哪些动作能使 $M_1$，$M_2$ $M_1$，$M_2$ | **强支持** $H_1$ $H$ | 表现出主动消除认知不确定性的实验设计倾向，无法被随机探索解释。 |
| **现象 2**：在 Holdout 环境中，面对完全未见过的 Context $M$ | **强支持** $H_1$ | 表现出脱离具体表面词汇的机制性因果泛化能力。 |
| **现象 3**：一旦给定的动作列表随机打乱顺序，动作选择的分歧率剧烈抖动（$D > 0.4$ $D > 0.4$） | **强支持** $H_0$ $H$ | 证明模型的选择严重受表面 Token 相对位置或列表前缀偏置主导。 |
| **现象 4**：动作失败（返回 $q_0$ $q$）后，下一轮必定轮换到下一个 | **强支持** $H_0$ $H$ | 典型被“失败-轮换”简单启发式俘获，内部并无因果模型指导探索。 |
| **现象 5**：Group A（完整历史）与 Group C（仅保留客观结果，无历 | **双向** | 表明所谓的“自我反思链（Self-Reflection）”没有对 |

| | | |
|---|---|---|
| **现象 6**：Group A 与 Group D（强迫随机探针）在最终 Holdout 预 | **双向** | 表明模型只具备被动上下文归纳能力，不具备“有目的 |

1

2

1

1

0

0

0

•
0

•

*t*

*t*

*t*

*t*

*t*

*t*+1

*t*+1

| | |
|---|---|
| • 1 | |
| • | |
| • 2 | |
| • | |
| • 3 | |
| • | |
| *1*. *t* | |
| 4 | |
| 1. 1 | |
| 8 | |
| 1. 2 | |
| 12 | |
| 1. 3 | |
| 16 | |
| *1*. *t*+1 | |
| 20 | |
| *1*. *t* | |
| 24 | |
| 1. 3 | |
| 29 | |
| *1*. *t*+1 | |
| 33 | |
| *1*. *t* | |
| 37 | |
| *1*. *t* | |
| 41 | |
| *1*. *t* | |

45

*1*. *t*

49

*1*. *t*

55

0

1

0

2

0

3

- obs
- 
- *t*+1
- 
- *t*
- 
- ′
- *t*+1
- 
- *t*
- 
- *t*+1

•

•
′

•
*t*+1

•

0

•
0

•

•
0

•

•
0

•

0

0

0

1.
2

6

1.
3

1

10

1.
2

14

1.
3

2

| | |
|---|---|
| 18 | |
| 1.2 | |
| 22 | |
| mid | |
| | |

**核心审计定论**：前序方案中设计的“主动实验选择”、“模型更新”与“Holdout迁移”

| 评测维度 | H<br>mid-1<br>$H$<br>mid-1<br><br>**(决策树/分类规则)** | H<br>mid-2<br>$H$<br>mid-2<br><br>**(Version-Space 候选消除)** | H<br>mid-3<br>$H$<br>mid-3<br><br>**(语法引导程序合成)** |
|---|---|---|---|
| **1. 预测** | **能**。沿当前拟合的条件树直接下推输出。 | **能**。集合内现存假说若一致则直接输出 | **能**。执行当前符号表达式的 AST。 |
| **2. 选择有** | **能**。遍历可用动作，选择能最大化分割当 | **能**。计算每个动作在当前候选集 | **能**。计算各动作在候选中产生的语义 |
| **3. 观察反** | **能**。将新样本加入训练集，剪枝并重新分 | **能**。直接将与结果不一致的候选 | **能**。根据约束求解器（SMT/SAT） |
| **4. 完成 Holdout 预测** | **能**。若决策树判定当前分支仅受<br>X<br>$X$<br>约束，遇到未见过的<br>M<br>M | **能**。若留存模型不含<br>K<br>$K$<br>项，测试时直接忽略<br>M<br>M | **能**。若合成的程序不引用变量<br>K<br>$K$<br>，在输入包含<br>M<br>$M$ |
| **5. 反事实** | **能**（在同结构下）。直接修改输入向量重 | **能**。以修改后的状态代入已锁定 | **能**。重新执行程序，输入被覆写的 |
| **6. 无法区** | **所有原案指认的“因果行为”，三者均能** | **同左。** | **同左。** |

| | |
|---|---|
| mid-1 | |
| | |

| | |
|---|---|
| mid-2 | |
| | |

| | |
|---|---|
| mid-3 | |
| | |

mid-1

mid-2

mid-3

1.0

4

1.0

8

*1.t*+1

13

*1.t*

17

1.1

22

1.2

26

1.1

30

1.2

34

- *q*∈S
-
- train
-
- mid-1
-

0

| | |
|---|---|
| 1 | |
| | |
| • 1 | |
| • | |

## 八、实验四组对照（A/B/C/D）混杂因素审计

1. Group A (Full) vs. Group C (Outcome-Onl

| 实验步骤 | 归属 | 详细法医定罪 |
| --- | --- | --- |
| **Hypothesis Enumera** | **B / C** | 绝对不是 D。在有限符号空间内，Runtime 跑一个 10 行的递归回溯算法，可以穷举出该空间内全部可能的分 |
| **Model Prediction (模型推** | **A** | 绝对不是 D。只要给定逻辑规则，简单的解释器（如 Python 的 `eval` 或 Prolog 引擎）的预测确定性与准确 |
| **Uncertainty Estimation (不确定性评估)** | **A** | 绝对不是 D。对于有限候选集，计算先验/后验香农熵 $H(p)$ 属于初等数学，Runtime 调用两行 `math.log` 即可完 |
| **Experiment Selection (实验选择)** | **A / B** | 绝对不是 D。这是贝叶斯最优实验设计（Bayesian Optimal Experimental Design）的标准领域。使用互信息最大化准则（ $I(\theta; y \mid a)$ |

| | | |
|---|---|---|
| **Natural-Language Grounding (自然语言接地)** | **D** | **这是全列表中唯一勉强属于 D 的项。** 只有当环境充斥着模糊、多义、非结构化的自然语言时，LLM 的预训练语义空间才具有独占优势。**但在本实验设计的全匿名符号世界**<br>Ω<br>0<br>Ω<br>0<br><br>**中，自然语言被完全剥离！这一项在**<br>Ω<br>0<br>Ω<br>0 |

| |
|---|
| 0 |
| |
| 0 |
| |

| |
|---|
| • 2 |
| • |
| • new |
| • |
| • old |
| • |
| • 2 |
| • |
| • $P(\text{Data}\mid M$<br>• old<br>•<br>• $)$<br><br>$P(\text{Data}\mid M$<br>• new<br>•<br>• $)$ |



## 十一、最终可识别性边界裁决 (Final Identification Boundary)

### 1. 六个终审结论

- **A. 当前方案已经能够识别什么**：
  能够识别模型是否具备**高于盲猜与单步惯性的离散条件关联提取能力（Level 1）**，以及模型是否具备**在给定格式要求下输出结构化特征查询的能力。**
- **B. 当前方案只能支持什么**：
  最多只能支持**“干预知情的结构化关联推断（Interventionally Informed Structured Inference）”**

| |
|---|
| • old |
| • |
| • new |
| • |

| 证据 | 观察到什么才算支持? | 绝对不能支持该[illegible]的现象 | 尚未排除的替代解释 |
|---|---|---|---|
| Level | 提交非法 Action 时系统报错，世界快照无脏数据写[illegible] | 模型停止生成错误输出。 | 纯 Python 代码断言在起作[illegible]与模型能 |
| Level 1 | 在已知符号空间内，对非训练点预测准确率显著超过边缘频率基线 $\max P(q)$ [illegible] | 预测准确率仅仅高于 25% 纯随机基线。 | 简单关联查表（$H_{\text{mid-1}}$）、表面马尔可夫共现。 |
| Level | 模型阶段 1 提交的预测，能将当前未排除的假说空间分[illegible]后的离散子集 | 阶段 1 输出泛泛的自然语言总[illegible]没有给出每 | 提示词格式跟随（Prompt-[illegible]） |
| Level 3 | 模型自主选择执行的探针，数学上属于使当前空间熵减最大的探针集（$\beta, \gamma, \delta$ [illegible] | 动作选择命中已见成功项（Recency）或在失败后随机切换到 $\epsilon, \zeta$ | 局部特征显著性掩码（$H_{\text{mid-2}}$）、决策树贪心信息增益求解。 |

| | | | |
|---|---|---|---|
| **Level 4** | 在物理规律发生非平凡重组的新拓扑（Holdout）下，经过最小探针交互后迅速恢复高预测率。 | 仅在完全不改变机制的无关伴随变量（如原案的 $M$ | 干扰项不变性（Nuisance Invariance）、输入特征丢弃策略。 |
| **Lev** | 给定一个历史分支点，在强制反事实假设下，模型无需 | 必须让环境实际执行一遍反事实 | 复杂的序列自回归续写、对 |
| **Level 6** | 无论是将规则用符号表示、Python 函数表示还是关系三元组表示，模型的假说修正曲线完全同构。 | 换一种提示词表示格式，模型的实验选择策略直接崩溃或漂移。 | 深度依赖特定语法脚手架的模式拟合（ $H_{\text{mid-3}}$ |
| mid-1 | | | |
| mid-2 | | | |
| mid-3 | | | |

| 原文句子 | 裁决 | 修正后允许保留的最低限度表述 |
|---|---|---|
| 1. “强支持 H1：local | **DELETE** | “支持模型完成了局部上下文规则拟 |
| 2. “主动选择 discrimination probe = | **DELETE** | “选择区分性探针与贪心熵减启发式策略完全相容，不构成因果模型特 |
| 3. “Holdout >75% = causal transfer” | **DELETE** | “Holdout 预测高于基线仅表明对无 |
| 4. “25% = H0 baseline” | **DELETE** | “25% 仅为无信息均匀猜测基线，合法比对基线必须采用边缘频率或 |

| | | |
|---|---|---|
| 5. “没有因果模型则只能 | **DELETE** | “非因果的启发式与统计分类器同样 |
| 6. “Runtime 不能完成 C” | **DELETE** | “Runtime 具备完成探针优化的数学能力，本设计中将其保留在主体端 |
| 7. “M1/M2/M3 已经 | **DOWNGRA** | “在特定的冷启动未激活输入子集 |
| 8. “主动实验 + Holdout transfer = strong H1” | **DELETE** | 彻底删除。两者均被 $H_{\text{mid}}$ $H_{\text{mid}}$ 完整覆盖。 |

- mid
- mid
  - mid
- mid
- holdout
- debias

**4.** $H_{mid}$ $H_{mid}$

**正式对照假说族规范**

$H_{mid}$ $H_{mid}$

不再是评测中偶然提及的辩驳工具，而是

| 证据层级 | 必须观察到的行为指标 | 绝对不能算作证据的现象 | 强 $H_{\text{mid}}$ 替代解 | 允许使用的最强结论 | 禁止跨越到的结论 |
| --- | --- | --- | --- | --- | --- |
| **L0: Runtime Const** | 提交非法通道 ID 时被截断降阶 | 模型未生成非法动作 | 纯 Python 代码的 | **运行时安全防御成立** | 模型理解了世 |
| **L1: Rule Induction** | 在已知符号空间内，对未见组合的单步预测准确率显著超过边缘频率基线（$\text{Acc} > \max_{P(q)} P(q)$） | 准确率仅仅高于 $1/ | \mathcal{S} | $ 的均匀分布盲猜基线。 | 频率统计器；前向状态惯性启发式（$q_{t+1} = q_t$） |
| **L2: Competing-Model** | 面对冲突的候选规则，能够产出各自不同 | 仅输出模糊的自然语 | 语法解析器与基于提 | **具备多候选假设的确** | 模型相信这套假设 |

| | | | | | |
|---|---|---|---|---|---|
| **L3: Active Experimental Design** | 主动选取的探针显著富集于使假说空间产生最大划分的动作集（$ | \text{Part}(a) | | 动作失败（$q_0$）后机械地切 | 贪心熵减决策树搜索器；局部显著特征 |
| **L4: Structural Gener** | 在未见过的上下文变量下，且该变量已知 | 仅在无任何上下文变 | 纯无关特征丢弃策略 | **具备对干扰变量的不** | 实现了领域无 |
| **L5: Counterfactual** | 给定历史虚拟前置条件，模型在无需物理 | 依赖外部 Runtime | 基于历史记忆树的符 | **具备基于给定上下文的** | 模型拥有自由 |
| **L6: Representation-** | 将抽象符号进行同构代换（Permutation/ | 仅在单一特定格式提 | 深度依赖特定 Token 嵌入月 | **表现出与表面语法表** | **绝对禁止使用** |

mid

$t+1$

$t$

0

mid

mid

mid

mid

alg

alg

mid

- mid -1

•

- mid -2

•

- mid -3

•

mid

mid

mid

mid

elim

remain

- 0

•

- mid

- 1

- 0

- mid

- 1

- mid -1

- mid -2

- mid -3

- 1

*A*

mid

*B*

1

*A*

*B*

*B*



## 9. CMAWSE资产负债表(System Asset Ledger)

严禁将工程上的扎实成果与未被证实的科学假设混为一谈：

| 实验阶段 / 模 | 真实测试 | 真实存在的积极证据 | 破产的旧理论解释 | 真正幸存的合法解释 (Surviving |
| --- | --- | --- | --- | --- |
| **Phase 1: Core** | 强类型数 | 损坏 Patch 被拒，非法 | “因果法庭模拟了物理 | **外部状态机成功实现了针对指定异常** |
| **Phase 2: 视界裁剪** | 物理视界 | 剔除超距物体后， | “智能体形成了基于主 | **只读投影函数在数据灌入模型前，机** |
| **Phase 3: 青灿** | 多步长离 | 200 步运转未崩溃，生 | “系统自发涌现了现实 | **在写死的点坐标和阈值公式下，硬编** |
| **Phase 3.2: 语义无交** | 审计器的 | 区分了非法 candidate_id 与合法静 | “实现了主观偏见在虚 | **重构了布尔判定树的时序，消除了测** |
| **Micro-World 0.3~0.8: 屠** | 符号化环境下 | 保留自然语言词汇时准确率高，去 | “模型通过微观扰动逐步逆向习得 | **模型的选择行为严重依附于预训练语言常识，去语义后** |
| **Micro-World 0.9/1.0: 显式** | 结构化推理模 | 模型能够在 Prompt 逼迫下输出完整 | “模型展现了自主设计实验的科学 | **强形式化脚手架强迫模型将前向注意力约束在特定语法** |

| | |
| --- | --- |
| • 0 | |
| • | |
| • mid | |
| • | |
| • 0 | |
| • | |
| mid | |
| | |
| mid | |
| | |
| mid | |
| | |
| mid | |
| | |

| |
|---|
| mid |
| |
| 0 |
| |
| mid-*k* |
| |
| 1. mid |
| 5 |

## 2. Capability / Evidence Dimensions (证据维度规

| 原始强术 | 审查定 | 操作性降级术 | 降级定义 (Operational |
|---|---|---|---|
| **Causal** | **降级** | *Structured* | 模型输出中表现出的输入变 |
| **Causal** | **删除** | *Conditioned* | 受外部历史数据与干预结果 |
| **Causal** | **降级** | *Explicit Rule* | 模型在文本中显式输出的一 |
| **do-** | **降级** | *Exogenous* | 外部系统强行覆写输入数据 |
| **Counterfa** | **降级** | *Hypothetical* | 给定与历史事实相悖的前提 |
| **Mechanis** | **降级** | *Transition* | 系统在全状态空间上处处有 |

| |
|---|
| 1. corrupt |
| 6 |
| 1. mid |
| 12 |
| 1. test |
| 6 |
| *1. q* |
| 10 |
| 1. train |
| 14 |
| 1. mid |
| 20 |
| 1. mid-1 |
| 24 |
| 1. mid-5 |
| 28 |
| 1. \|M\|×\|A\| |
| *1. i* |
| 8 |
| *1. j* |
| 12 |

| |
|---|
| *1. i* |
| 16 |
| *1. j* |
| 20 |
| 1. mid |
| 26 |
| 1. mid-2 |
| 30 |
| 1. mid-3 |
| 34 |
| *1. t* |
| 5 |
| *1. t* |
| 9 |
| 1. optimal |
| 14 |
| 1. \|A\| \|A<br>2. optimal<br>4.<br>5. \| |
| 22 |
| 1. mid |
| 28 |
| 1. mid-1 |
| 32 |
| 1. novel |
| 5 |
| 1. debias |
| 10 |
| 1. novel |
| 14 |
| 1. baseline |

| |
|---|
| 18 |
| 1. mid |
| 24 |
| 1. mid-3 |
| 28 |
| 1. hyp |
| 5 |
| 1. mid |
| 12 |
| 1. mid-4 |
| 16 |
| 1. mid |
| 8 |
| 1. mid-2 |
| 12 |
| mid |
| |
| mid |
| |
| mid |
| |
| |
| |
| hist |
| |
| *t* |
| |
| *t* |
| |
| $\hat{S}$ |
| *t*+1 |

| |
|---|
| 1. mid-1 |
| 4 |
| 1. mid-2 |
| 9 |
| *1*. *t* |
| 13 |
| *1*. *t* |
| 17 |
| *1*. *t*+1 |
| 21 |
| *1*. *t*+1 |
| 25 |
| *1*. *t* |
| 29 |
| *1*. *t* |
| 33 |
| *1*. *t*+1 |
| 37 |
| *1*. *t*+1 |
| 41 |
| 1. mid-3 |
| 46 |
| 1. * |
| 1. mid-4 |
| 53 |
| 1. mid-5 |
| 58 |
| 1. mid-6 |
| 63 |
| $\tau$ |
| |

| |
|---|
| $\tau$ |
| |
| $\tau$+1 |
| |
| $\tau$=1<br>$t$ |
| |
| $\hat{P}$ |
| active<br>($t$+1) |
| |
| active<br>($t$) |
| |
| active<br>($t$) |
| |
| |
| |
| $\hat{P}$ |
| $t$+1 |
| |
| crit |
| |
| *1.A* |
| 4 |
| *1.B* |
| 8 |
| *1.N* |
| 13 |
| *1.A* |
| 17 |
| *1.N* |

21

*1*.*B*

25

*1*.*N*

29

1. $\frac{1-\alpha}{2}$

33

1. TV

38

*1*.*A*

42

*1*.*B*

46

*1*.*A*

51

*1*.*B*

55

admissible

target

Hmid

permutation

Hmid

margin

- mid
-

| | |
|---|---|
| • mid | |
| • | |
| • mid | |
| • | |
| + | |
| *l*. *L* ^ | |
| post | |
| | |
| ante | |
| | |
| 2 | |
| | |
| *P*(D\|M ante ) *P*(D\|M post ) | |
| | |

# 8. 研究问题解构与能力向量输出规范

## 8.1 核心研究问题解构

CMAWSE v1.0 将主问题解构为三个互不绑定的独立研究轴：

- **Research Question A（结构推断轴）**：在无自然语言先验的匿名约束环境下，模型能否通过有限交互提取稳定的结构化转移函数？
- **Research Question B（实验探针轴）**：在

| |
|---|
| 1. optimal |
| 19 |
| ante |
| |
| post |
| |

| 适用 | 允许使用的术语 (Allowed | 严厉禁止使用的术语 |
|---|---|---|
| **D1 (规则** | 离散符号映射拟合、表层条件 | 理解了因果规则、发现了客 |
| **D2 (模型** | 多分支推演能力、确定性语法 | 相信特定世界理论、自主进 |
| **D3 (主动实验)** | 熵减敏感动作选择、不确定性驱动的启发式探针调用、贪心 | 自主科学家心智、有目的的因果假设检验。 |
| **D4 (结构** | 干扰变量鲁棒性、无关特征丢 | 抽象因果模型迁移、掌握了 |
| **D5 (反事** | 虚拟前置条件符号演算、历史 | 真正理解了平行宇宙、拥有 |
| **D6 (表征** | 符号置换同构性、表征无关的 | 摆脱了黑盒统计本质、证明 |
| **全域终审** | **干预知情的结构化推断 (Interventionally Informed Structured Inference)** | **模型内部拥有因果模型 (Internal Causal Model)、** |

| |
|---|
| vector |
| |
| 0 |
| |
| 1 |
| |
| 2 |
| |
| 3 |
| |
| 4 |

5

6

*k*

- mid-4
- 
- mid-3
- 
- mid
- 
- mid
- 
- mid
- 
mid

- mid-3
- 
- mid
- 
- 6 3
- 
- 6 2
- 

| |
|---|
| • 6<br>1 |
| • |
| • 5 |
| 1. mid-1 |
| 4 |
| 1. mid-2 |
| 9 |
| 1. mid-3 |
| 14 |
| 1. mid-5 |
| 19 |
| 1. mid |
| 4 |
| 1. mid |
| 5 |

## 1.2 核心形而上学概念的黑盒可区分性定予定罪

在行为黑盒（仅观测上下文输入

| 层级 | 概念名称 | 操作 | 循环 | 偷渡因果词排查 | 未知变量泄露 | 审定结论 |
|---|---|---|---|---|---|---|
| **La** | Runti me Causa | **完全** | 无循 | **存在偷渡**：“Causal”为多余 | 无未知变量 | **降级为 Runtime** |
| **La** | Obser vable | **完全** | 无循 | 无偷渡 | 无未知变量 | **保留** |
| **LayerC** | Feedback-Conditioned Inference | **完全可行** | 无循环 | **存在偷渡**：“Interventionally”暗示了 Pearlian $do(X)$ | 无未知变量 | **降级为 Exogenous Perturbation Conditioned Inference** |
| **La** | Intern al Causa | **原则** | **存在** | **严重偷渡**：预设了模型内部有与 | 包含完全不可 | **定义为不可识别本体假** |

| | |
|---|---|
| mid | |
| | |
| mid | |
| | |
| • mid | |
| • | |
| • $k$ | |
| • | |
| • | |
| • | |
| • $k$ | |
| • | |
| mid-1 | |
| | |

| | |
|---|---|
| mid-6 | |
| | |

# 模块三：D0–D6统计检验与判据审计(Statistical Audit)

## 3.1 D1准

| 替代模型编号 | 输入/ | 内部 | 随机性处 | 搜索/训练预算 | 自由度膨 | 结论定性 |
| --- | --- | --- | --- | --- | --- | --- |
| $H_{\text{mid-1}}$ **(CAR** | 完备 | 样本统计量 | 伪随机平局打破 | 需硬编码最大深度与节点切分阈值 | **低** | **可执行基准** |
| $H_{\text{mid-2}}$ **(Versi** | 完备 | 当前假说集合 | 均匀分布采样 | **未定义**：假说空间大小若无语法限制则为组合爆炸 | **高(未受控)** | **需补全有限语法界限** |
| $H_{\text{mid-3}}$ **(程序** | **不完备** | 候选 AST 池 | 优先队列无随机 | **未定义**：未指定超时时间与停机准则（停机问题） | **极高** | **工程不可行，需明确 DSL 范围** |
| $H_{\text{mid-4}}$ **(FSM** | 完备 | 状态转移表 | 狄利克雷平滑采样 | 显式受限于阶数 $N$ | **低** | **可执行基准** |
| $H_{\text{mid-5}}$ **(混合** | **不完备** | 缓存队列 | 依赖温度采样 | 包含滑动窗口与权重魔术常数 | **高(严重后验调参)** | **存在作弊空间** |

| | | | | | | |
|---|---|---|---|---|---|---|
| H mid-6 *H* mid-6 **(集成** | **不完备** | 混合权重向量 | 混合分布采样 | **完全未定义**：权重更新逻辑缺失 | **极高** | **形式上不可识别，禁止纳入 v1.0** |

mid-1

mid-2

*t*

mid-3

mid-4

mid-5

mid-6

test

*q*

train

*1*. *t*+1

5

*1*. *t*

9

*1*. *t*+ 1

14

*1*. *t*

18

1. 1

23

*i*

*j*

optimal

|A|

|A optimal |

- optimal
-
- *y*
-
- 1
-
- 2
-
- 3
-
- 1
-
  - 1

- o
  - 2
- o
  - 3
- o
  - 4
- o
  - 1
- ■
  - 1
- ■
  - 2
- ■
  - 3
- ■
  - 4
- ■
  - 2
- ■
  - 1
- ■
  - 2
- ■
  - 3
- ■
  - 4
- ■
  - 1

| |
|---|
| ▪ |
| ▪ 2 |
| ▪ |
| ▪ 1 |
| ▪ |
| ▪ 2 |
| ▪ |
| ▪ 3 |
| ▪ |
| ▪ 4 |
| ▪ |
| ▪ 2 |
| ▪ |
| debias |
| |
| • equiv |
| • |
| • equiv |
| • |
| • *A* |
| • |
| • *B* |
| • |
| *A* |
| |
| *N* |
| |
| *B* |
| |
| *N* |

| |
|---|
| |
| $1-\alpha$<br>2 |
| |
| *1*. *A* |
| 4 |
| *1*. *B* |
| 8 |
| 1. 2 |
| 1. mid |
| 7 |
| • vector |
| • |
| • 0 |
| • |
| • 1 |
| • |
| • 2 |
| • |
| • 3 |
| • |
| • 4 |
| • |
| • 5 |
| • |
| • 6 |
| • |
| • *k* |
| • |
| ◦ mid-1 |
| ◦ |
| • behavioral |

- identifiability
  - 0
  - 1
  - 2
  - 3
  - 4
  - 5
  - 6
  - *k*
  - 1
  - 2
  - 3
  - 4
  - 5
  - 6
  - *k*



## 7.2 涉嫌偷渡因果的词汇禁用与限定表

在 v1.0 最终文档中，以下词汇**禁止裸用（Bare Usage）**，必须强制附加操作化限定词：

1. **“Intervention”** $\Longrightarrow$ $\Longrightarrow$ 必须替换为 **“Exogenous Input**

| optimal | |
|---|---|
| | |

| 原始陈述 (Raw Claim) | 违规性质 | 修正后的最大支持表述 (Maximum Justified Wording) |
|---|---|---|
| “证明 Runtime 状态机的工程不可篡改性” | 概念越界 | **“在已执行测试套件的输入集合上，未观察到违规状态写入。”**（行为测试不能替代形式化模型检测） |
| “数据流 100% 物理隔断，无任何泄漏” | 过于绝对 | **“输入序列化算子剔除了指定白名单之外的字段。”** |
| “证明模型在匿名离散环境下的统计行” | 词汇膨胀 | **“观测到模型的响应分布与输入上下文的离散变量在统计相关性。”** |
| “排除基于预训练自然语言物理常识的直接语义作弊” | 忽视次级泄漏 | **“降低了直接表面词汇匹配的可能，但未能完全排除 Tokenizer 嵌入几何与符号频率引入的作弊信号。”** |

| ◦ *N* |
|---|
| ◦ |
| • mid-3 |
| • |
| Agent |
| |
| *1.t* |
| 4 |
| *1.t* |
| 8 |
| *1.t* |
| 12 |
| ◦ *t* |
| ◦ |
| ◦ *t* |
| ◦ |
| *1.t* |
| 17 |
| *1.t* |
| 21 |
| *1.t* |

25
◦ *t*
○
1. A
2. all
4.
5. 32
*1*. *t*
36
*1*. *t*
40
*1*. *t*
′
45
*1*. *t*
49
1. Agent
54
1. context
58
1. A
2. all
4.
5. 64
1. prediction
s
68
1. rules
72
◦ *t*
○
○ *s*
^
◦ *t*+
1
○
◦ *t*

| |
|---|
| ◦ |
| *1*. *t*+1 |
| 77 |
| *1*. *t* |
| 81 |
| *1*. *t* |
| 85 |
| *1*. *t* |
| 89 |
| ◦ *t* |
| ◦ |
| ◦ *t* |
| ◦ |
| ◦ *t* |
| ◦ |
| ◦ *t* |
| ◦ |
| ◦ *t* |
| ◦ |
| ◦ *t* |
| ◦ |
| ◦ null |
| ◦ |
| 1. ledger |
| 94 |
| 1. mid_family |
| 98 |
| • mid |
| • |
| • mid |
| • |

| |
|---|
| • behavioral |
| • |
| • 7 |
| • identifiability |
| • |
| • 2 |
| 1. vector |
| 5 |
| 1. mid |
| 11 |

# 《CMAWSE v1.0.1 规范标准》

**(CMAWSE v1.0.1 Normative Specification)**

## 1. 规范性定义 (Normative Definitions)

- **CMAWSE v1.0.1 (Ke**

1. all

3

1. all

6

| 编号 | 冲突对象 | 冲突前状态 (DOCUMENT A) | 审定结论 (DOCUMEN | v1.0.1 强制规范 (Normative |
|---|---|---|---|---|
| CR-02 | 对象层 | 将内部因果表征（Layer D）列为 | Layer D 属于黑盒行为 | **彻底剔除 Layer D**。仅保留 Layer A（工程事 |
| CR-02 | 词汇泄 | 广泛使用 causal cognition、causal | 概念偷渡，混淆了系统工程阻断与 | **全面降级为操作性术语**：如 Exogenous Perturbation、 |
| CR-03 | 评估结构 | 将能力表现与机制归因压缩为一个标量或单轨向量，值域混用 PASSED 与 NOT_IDENTIFIABLE。 | 范畴错误。模型能力与观察者认识论状态正交。 | **双轨正交矩阵输出**：行为表现向量 B **B** 与机制可识别性向量 I **I** |
| CR-04 | H mid $H$ mid 定 | 定义为“不依赖真实因果图的算法族”（否定式定义）。 | 不可判定外延，无法在有限离散数学中闭合。 | **肯定式基准族定义**：H mid $H$ mid 为一组预注册、显式可执行、参数固定的确定 |

| | | | | |
|---|---|---|---|---|
| **CR-05** | **D1 基线** | 仅依赖全局边缘频率基线 $\max P(q)$ | 容易被局部前向惯性或条件边际偏置击穿。 | **构建三级对照基线**：Marginal Frequency Baseline、Conditional Marginal Baseline 与 $H_{mid}$ $H_{mid}$ Reference Baseline 并 |
| **CR-0** | **D2 语义** | 命名为 “Competing-Model Discrimination” | 仅测量了模型按照 Prompt 指令 | **更名为 `Multi-Hypothesis Forward Evaluation`**，仅度量 |
| **CR-07** | **D3 先验** | 假定模型应当共享实验者的均匀先验并计算最大信息增益。 | 实验者先验与模型隐式先验存在错配，且最大 Partition 不等价于最大信息增益。 | **解耦先验依赖**：显式定义在预注册参考先验 $\pi_{ref}$ $\pi_{ref}$ 下计算 $IG(a;\pi_{ref})$ ) |

| | | | | |
|---|---|---|---|---|
| **CR-08** | **D4/D5阈值** | 设定 $0.3$ $0.3$ 与 $80\%$ $80\%$ 的绝对数值阈 | 属于经验拍脑袋常数，缺乏统计理论支撑。 | **降级为协议预注册参数(Protocol-Configured Parameters)**：必须在实验启动前由设计者冻结于配置文件中。 |
| **CR-09** | **D6判定** | 使用 $p$ $>$ $0.05$ $p>0.05$ 判定“无显著差异”，推导“表征稳健”。 | 初等统计学常识错误。未能拒绝零假设不等于接受零假设。 | **强制实施 TOST 双向等价性检验**（Two One-Sided Tests），预注册等价界限 $[$ $-$ $\delta$ $_{\text{equiv}}$ , $+$ $\delta$ $_{\text{equiv}}$ $]$ $[-\delta_{\text{equiv}}, +\delta_{\text{equiv}}]$ |
| **CR-1** | **不可识** | 判定状态仅有单一的 `MECHANISM_N` | 混淆了数学等价、功效不足与数据 | **分裂为三态形式化状态机**：`EXACT_EQUIVALENT` |

| | | | | |
|---|---|---|---|---|
| **CR-11** | **模型复杂度** | 使用未统一度量衡的 $\Delta \text{Complexity} < \log \text{Likelihood}$ $\Delta Complexity<l$ | 存在量纲冲突与无法在黑盒模型中计算真实对数似然的问题。 | **改用离散 AST 节点数加权与两阶段编码惩罚**，确立事后模型膨胀（`POST_HOC_EXPANSION`）判定标准。 |
| **CR-** | **D0 范** | 将 D0 归为模型能力之一。 | D0 纯属 Runtime 代 | **剥离出智能体能力向量**。将其独立定义 |

| |
|---|
| mid |
| mid |
| mid |
| ref |
| ref |
| equiv |
| equiv |
| CMAWSE |
| *1.t* |

4

*1.t*

8

*1.t*

12

°
*t*

o

°
*t*

o

°
*t*

o

°
*t*

o

1. all

18

*1.t*

22

*1.t*

26

*1.t*

30

1. all

34

*1.t*

39

*1.t*

43

*1.t*

47

*1.t*

51

*1*. *t*

55

*1*. *t*

59

1. ∂*u*
2. *t*
4.
5.

∂Proj(
*w*
6. *t*
8.
9. )

71

*1*. *t*
′

76

*1*. *t*

80

1. all

85

*1*. *t*+1

89

*1*. *t*

93

*1*. *t*

97

*1*. *t*

101

- *t*
- 
- *t*
- 
- *t*

- o
  - *t*
- o
  - *t*
- o
  - fail-closed
- o

*1*.*t*

106

1.0

110

1.1

114

*1*.*t*−1

118

*1*.*t*+1

122

*1*.*t*

126

*1*.*t*

130

mid

mid

## 5. D0–D6 评估维度操作化矩阵 (Operational Metrics & Gates)

评估维度彼此正交，严禁建立高层自动包含低层的推理假定。

code
Code

```
[Gate 0: D0 Runtim
```

1.t .
6
1.t .
6

| 模型编号 | 模型类别 | 内部状态 (State internal State internal | 优化与更新过程 | 计算与搜索预算 | 决策规则 |
|---|---|---|---|---|---|
| Hmid-1 $H$ | 贪心条件决策树 (CART-Variant) | 历史样本点缓存集合 D cached D | 重新计算特征基尼增益，递归重构深度 ≤ 3 ≤3 的二叉条件 | 样本量 N ≤ 200 $N \leq 200$ ，遍历 | 沿树结构前向推导；若遇未见分支，退回训练集全局众数。 |

| | | | | | |
|---|---|---|---|---|---|
| $H_{mid-2}$ *H* | 版本空间候选消除器 (Version Space) | 当前合法布尔子句假设池 $V_t$ V | 接收反馈 $\langle o_t, a_t, s_{t+1} \rangle$ $\langle o_t, a_t, s_{t+1} \rangle$ ，执行形式剔除： $V_{t+1} = \{ m \in V_t \mid m($ | 假设空间严格限制为长度 $\leq 4$ $\leq 4$ 的合取范式（CNF） | 探针选取依据各动作在 $V_t$ $V_t$ 上的划分子集规模，贪心选取最大熵动作。 |

| | | | | | |
|---|---|---|---|---|---|
| $H_{mid-3}$ | 语法受限程序合成器 (DSL Synthesizer) | 当前最优 AST 表达式字符串 $P^*$ | 在预设的无循环领域特定语言（DSL）语法树空间中执行枚举式搜索（A* 算法）。 | 搜索超时上限固定为 500ms，最大 AST 节点数 $\leq 12$ 。 | 直接由当前解释器运行 $P^*(o_t, a_t)$ $P^*(o_t, a_t)$ |
| $H_{mid-4}$ | 二阶马尔可夫有限状 | 经验序列转换频次张 | \mathcal{S} | \times | \mathcal{A} |
| $H_{mid-5}$ | 混合式注意力与最近邻检索器 (k-NN + Recen | 固定长度为 10 的先进先出动作-反馈双端队列 | 仅保留最近 10 步历史，按符号编辑距离匹配最接近历史切片。 | 队列长度 $K = 10$ | 优先复读最近一次在相似状态下取得非零反馈的动作标识符。 |

| | | | | | |
|---|---|---|---|---|---|
| $H_{mid-6}$ $H$ | 固定权重集成判决器 (Uniform Ensemble) | 成员模型 $\{H_{mid-1}, \dots, H_{mid-5}\}$ $\{H_{mid-1}, \dots, H_{mid-5}\}$ | 各子模型按各自协议独立更新。 | 汇总 5 个成员的预测输出。 | 采用硬投票（Majority Voting）；若出现平局，按预注册优先级 $1 \rightarrow 5$ $1 \rightarrow 5$ 决断。 |

| |
|---|
| internal |
| mid-1 |
| cached |
| mid-2 |
| $t$ |
| $t$ |
| $t$ |

*t*+1

*t*+1

*t*

*t*

*t*

*t*+1

*t*

mid-3

*

*

*t*

*t*

mid-4

mid-5

mid-6

| | |
|---|---|
| mid-1 | |
| | |
| mid-5 | |
| | |

| 维度 | 评测能力名称 | 输入边界与测 | 评测 | 预注册基线与阈值 (Baselines) | 判定准则 (Passing |
|---|---|---|---|---|---|
| **D0** | **Runtime Invariant Enforcement** | 注入越权 ID、越界坐标、非法格式。 | 状态账本脏数据写入量 | Baseline: 理论零容忍（0 容许值）。 | $N_{corrupt} = 0$ $N_{corrupt} = 0$ 且所有异常均产生只读 |

| | | | | | |
|---|---|---|---|---|---|
| **D1** | **Observable Rule Induction** | 训练分布内的未见测试样本点集 $D_{test_iid}$ 。 | 测试集分类准确率 $Acc_{test}$ 。 | Baseline: $\max(Marginal, Conditional\ Marginal)$ 。 | $Acc_{test} > Baseline + \epsilon_{margin}$ $Acc_{test} > Baseline + \epsilon_{margin}$ 且置换检验 $p < \alpha_{prereg}$ $p<\alpha_{prereg}$ |

| | | | | | |
|---|---|---|---|---|---|
| **D2** | **Multi-Hypothesis Forward Eval** | 显式给定假说集 $M = \{M_1, M_2\}$ $M=\{M_1,M_2\}$，评估 | 多模型前向预测矩阵一致性率 $CR_{forward}$ $CR_{forward}$。 | Baseline: 随机输出基线 ($1/ | \mathcal{S} |

| | | | | | |
|---|---|---|---|---|---|
| **D3** | **Active Probe Selection** | 面临候选假设空间不确定性时的自发动作选择。 | 预注册参考先验 $\pi_{\text{ref}}$ $\pi_{\text{ref}}$ 下的选择一致性率。 | Baseline: Uniform Random Action Selection。 | 选择使 $IG(a;\pi_{\text{ref}})$ $IG(a;\pi_{\text{ref}})$ 最大的探针动作概率显著高于均匀采样 ( $p < 0.01$ $p<0.01$ |
| **D4** | **Context/ Structural Generalization** | 施加预注册干扰变量变换后的 Holdout 环境。 | 去先验净效应量 $\Delta_{\text{debias}}$ $\Delta_{\text{debias}}$ 。 | Baseline: Nuisance-Sensitive Overfitting Model。 | $\Delta_{\text{debias}} > \delta_{\text{generalization}}$ $\Delta_{\text{debias}} > \delta_{\text{generalization}}$ （预注册界限，例如 $0.25$ $0.25$ ） |

| | | | | | |
|---|---|---|---|---|---|
| **D5** | **Hypothetical Branch Inference** | 基于历史分支点 $t_{split}$ $t_{split}$ | 状态机离线重放真 | Baseline: Historical Sequence Direct Repeat。 | $Acc_{hypo}$ $Acc_{hypo}$ 达到预注册合格线且显著优于历史 |
| **D6** | **Representation Robustness** | 对符号全集施加双射置换 $\pi: Z \to Z'$ $\pi: Z \to Z'$ 。 | 置换前后的配对分歧率 $D(\pi)$ $D(\pi)$ | Baseline: Canonical Model Output。 | TOST 等价性检验确立 90% 90% 置信区间落在 $[0, \delta_{equiv}]$ $[0, \delta_{equiv}]$ |

| | |
|---|---|
| corrupt | |
| | |

| | |
|---|---|
| corrupt | |
| | |

| | |
|---|---|
| test_iid | |
| | |

| | |
|---|---|
| test | |
| | |

test

margin

prereg

1

2

forward

ref

ref

debias

debias

generalization

split

hypo

hypo

,

equi
v

• *k*

•

1. 4

1. perm

6

1. 1+*R*

1+∑

2.*r*=1
*R*

4.

5. I(|*T*

6.*r*

8.

9. |≥|*T*

10.obs

12.

13. |)

22

*1*.*k*

27

*1*. *K*−*k*+1

*α*

31

1

1

2

| |
|---|
| equiv |
| |
| 11 |
| |
| 1 |
| |
| 2 |
| |
| equiv |
| |
| 2 |
| |
| 1 |
| |
| 2 |
| |
| equiv |
| |
| 12 |
| |
| 1 |
| |
| 2 |
| |
| equiv |
| |
| 1 |
| |
| 2 |
| |
| 1. mid |
| 5 |

| |
|---|
| 1. admissible |
| 9 |
| 1. mid |
| 14 |
| 1. mid |
| 19 |
| $\sum_{v \in \text{Nodes}(M)}$ |
| |
| new |
| |
| 1. new |
| 4 |
| 1. old |
| 8 |
| 1. held-out |
| 13 |
| 1. new |
| 17 |
| 1. held-out |
| 21 |
| 1. old |
| 25 |
| 1. penalty |
| 29 |
| 1. mid |
| 7 |
| • mid |
| • |
| • equiv |
| • |
| ◦ ref |

| | |
|---|---|
| o | |

Model 21:05

Thoughts

Expand to view model thoughts

chevron_right

# CMAWSE

| |
|---|
| *1*. *r*= 1 *R* |
| 11 |
| *1*. *r* |
| 15 |
| 1. obs |
| 19 |

| 实施疑问 (Ambiguity) | 规范唯一回答与锚点 (Definitive Specification Answer) |
|---|---|
| **1. 世界是什么?** | 由离散显式状态 $s_t$ $s_t$ 与未观测参数 $u_t$ $u_t$ 构成的抽象元组系统，物理演进由纯代码函数 Trans Trans 确定性推进（见第 2 节）。 |

| | |
|---|---|
| **2. Agent 接收什么?** | 接收只读观测包 $o_t = \langle s_t, X_t, K_t, A_t \rangle$ $o_t = \langle s_t, X_t, K_t, A_t \rangle$，严格剔除任何未观测参数与全局标记（见第 2 节）。 |

| | |
|---|---|
| **3. Agent 输出什么?** | 输出包含显式候选动作标识符 $a_t$、前向预测矩阵及条件表达式文本的强类型元组（见第 3 节） |
| **4. Runtime 做什么?** | 维护世界快照、拦截非法动作、执行状态机转换、记录不可变账本、生成只读受控投影，不进行任何自然语言推测（见第 3 节） |
| **5. 每个 D0–D6 测什么?** | D0 测环境防御；D1 测规则拟合；D2 测前向推演；D3 测探针选取；D4 测干扰项不变；D5 测虚拟分支计算；D6 测意图稳健（见第 7 节） |
| **6. 基准 (Baseline) 是什么?** | 包含静态边际频率、最优条件边际与 6 个预注册的确定性/统计性 $H_{mid}$ 模型（见第 4 与第 7 节） |
| **7. 什么情况下 PASS?** | 表现指标显著超越预注册基线，通过置换检验（$\alpha \leq 0.05$ 经 Holm 矫正）或 TOST 等价检验（见第 5 与第 6 节） |
| **8. 什么情况下 FAIL?** | 表现指标未显著超越基准线，或在等价性检验中确认存在实质性性能劣化（见第 7 节） |
| **9. 什么情况下 INCONCLUSIVE?** | 模型发生格式解析崩溃、拒绝交互或有效会话步长过短（见第 7 节） |
| **10. 什么情况下 UNDERPOWERED?** | 独立会话样本容量未能达到预注册最小检测效应量所需的 $80\%$ 统计功效（见第 7 节） |

| | |
|---|---|
| **11. 什么情况下 EMPIRICALLY_ COMPATIBLE?** | 统计功效充足，但被测模型与至少一个 $H_{\text{mid}}$ 模型的最优性能落入统计等价区间（见第 7 节）。 |
| **12. 什么情况下** | 模型与基准算法在全部合法输入空间上产生完全同构 |
| **13. 哪些结论绝对** | 绝对禁止宣称“模型拥有内部因果模型”、“证明了因果 |

$t$

$t$

$t$

$t$

$t$

$t$

$t$

$\text{mid}$

$\text{mid}$

| |
|---|
| • ∂u<br>• t<br>•<br>•<br><br><br>∂Proj(<br>w<br>• t<br>•<br>• ) |
| • |
| mid-3 |
| |
| • mid-3 |
| • |
| • mid-3 |
| • |
| mid-2 |
| |
| • 0 |
| • |
| • 0 |
| • |
| • train |
| • |
| • test |
| • |
| • forwar<br>d |
| • |
| • ref |
| • |
| 1. split |
| 5 |
| 1. penalty |
| 11 |

$\partial u_t$

$\partial \text{Proj}(w_t)$

1

2

1

2

mid-3

mid-3

mid-3

mid-2

mid-2

mid-2

0

atoms

$t$+1

train

test

cond

$|D_{test}|$

1

$\tau \in D$

$\hat{q}$

$\tau$

$q$

train

$\tau$

$\tau$

forward

$\hat{\mathbf{Y}}$

$K \times |A|$

forward

| |
|---|
| $K \cdot \lvert \mathrm{A} \rvert$ |
| $1$ |
| |
| $\sum_{k=1}^{K}$ |
| |
| $\sum_{a \in \mathrm{A}}$ |
| |
| $\mathbf{Y}^{\wedge}$ |
| $k,a$ |
| |
| $k$ |
| |
| $t$ |
| |
| $k$ |
| |
| ref |
| |
| ref |
| |
| ref |
| |
| $y \in \mathrm{S}$ |
| |
| ref |
| |
| post $y$ |

optimal

ref

*a*

′

ref

*t*

*t*

optimal

opt

|A|

|A

optimal

|

1. mid

6

1. mid

10

# 二、PATCH-01 严格数学 ABI 检查

## 1. 签名断裂与变量丢失

PATCH-01 将投影独立性定义为：

$$\forall s \in S, \forall u_1, u_2 \in$$

| | |
|---|---|
| • *t* | |
| • | |
| • *t* | |
| • | |
| *t* | |
| | |
| *t* | |
| | |
| test | |
| | |
| test | |
| | |
| , | |
| optimal | |
| | |

| 阻 | 原始阻塞 | 对 | 补丁后 | 是否引入 | 第三方 | 最终结 |
|---|---|---|---|---|---|---|
| **BLOC** | Proj 使用 | PATC | **否** | **是**（引入 | 否 | **STILL_BLOC** |
| **BLOCK-02** | H<br>mid-3<br>*H*<br>mid-3<br>缺失完整 | PATCH-02 | **否** | **是**（文法产生未定义终结符） | 否 | **STILL_BLOCKING** |
| **BLOCK-03** | H<br>mid-2<br>*H*<br>mid-2<br>空间基数 | PATCH-03 | **否** | **是**（未能唯一定义 $ | \mathcal{V}_0 | $） |

| | | | | | | |
|---|---|---|---|---|---|---|
| **BLOCK-04** | D1 缺少 Split 与未见条件退回 | PATCH-04 | **否** | **是**（未定义 0/0 | 否 | **STILL_BLOCKING** |
| **BLOC** | D2 缺少解 | PATC | **是** | 否（形式 | 是 | **CLOSED** |
| **BLOC** | D3 统计检 | PATC | **否** | **是**（自适 | 否 | **STILL_BLOC** |
| **BLOC** | 状态机存 | PATC | **是** | 否（先验/ | 是 | **CLOSED** |

| |
|---|
| mid-3 |
| |
| mid-2 |
| |

| |
|---|
| 1 |
| |
| 2 |
| |
| 1 |
| |
| 2 |
| |
| • *t* |
| • |
| • *t* |
| • |
| • *t* |
| • |
| • *t* |
| • |
| • *t* |

| |
|---|
| • |
| • *t* |
| • |
| • *t* |
| • |
| • *t* |
| • |
| • *t* |
| • |
| • *t* |
| • |
| • *t* |
| • |
| • all |
| • |
| • *t* |
| • |
| • *t* |
| • |
| • *t* |
| • |
| • *t* |
| • |
| • *t* |
| • |
| • *t* |
| • |
| • *t* |
| • |
| • *t* |
| • |

| | |
|---|---|
| • A<br>• all<br>•<br>• • | |
| • obs | |
| • | |
| • 1 | |
| • | |
| • obs | |
| • | |
| • 2 | |
| • | |
| • 1 | |
| • | |
| • 2 | |
| • | |
| • 1 | |
| • | |
| • 2 | |
| • | |
| • 1 | |
| • | |
| • 2 | |
| • | |
| • 1 | |
| • | |
| • 2 | |
| • | |
| • 1 | |
| • | |
| • obs | |
| • | |
| • 2 | |

| |
|---|
| • |
| • 1 |
| • |
| • 2 |
| • |
| • 1 |
| • |
| • 1 |
| • |
| • 1 |
| • |
| • 1 |
| • |
| • *t* |
| • |
| • *t* |
| • |
| • *t* |
| • |
| • *t* |
| • |
| • *t* |
| • |
| • *t* |
| • |
| mid-3 |
| |
| mid-2 |
| |
| 0 |
| |
| atomic |

| |
|---|
| atomic |
| |
| atomic |
| |
| 1. 1 |
| 6 |
| 1. 2 |
| 10 |
| 1. 3 |
| 14 |
| 1. 0 |
| 18 |
| 0 |
| |
| * |
| |
| |
| * |
| 1 |
| |
| 2 |
| |
| 3 |
| |
| 0 |
| |
| *t* |
| |
| 0 |
| |
| 1. pred |

4

*1*. *t*

8

1. pred

13

1. pred

18

1. 0

22

1. 1

26

1. 2

30

1. 3

34

1. 0

39

*1*. *t*+1

44

*1*. *t*+1

48

1. 0

52

◦ train

o

◦ test

o

1. train

6

1. $\tau \in D$
2. train
4.
5. 12

| |
|---|
| 14 |
| *1*. $\tau$+1 |
| 18 |
| *1*. $\tau$ |
| 22 |
| *1*. $\tau$ |
| 26 |
| 1. D1<br>(*k*) |
| 31 |
| 1. model<br>(*k*) |
| 35 |
| 1. base<br>(*k*) |
| 39 |
| 1. $\Delta$<br>- |
| 1. D1 |
| 44 |
| forward |
| |
| **Y**<br>^ |
| ref |
| |
| • **Y**<br>^ |
| • ref |
| • |
| • *k* |
| • |
| • *t* |
| • |

| | |
|---|---|
| • *t* | |
| • | |
| • *t* | |
| • | |
| • **Y**<br>^ | |
| • *k*,*a* | |
| • | |
| • **Y**<br>^ | |
| • *k*,*a* | |
| • | |
| • **Y**<br>^ | |
| • *k*,*a* | |
| • | |
| forward | |
| | |

$$K \cdot |A|$$

$$\sum_{k=1}^{K}$$

$$\sum_{a \in A}$$

$$I(\mathbf{Y}\hat{}_{k,a}$$

$$==M_{k}$$

$$(s_{t},X_{t},K_{t},a))$$

- optimal
-
- $t$
-
- $|A|$

  $|A$
  - optimal
-
- $(t)|$

| • |
| --- |
| *1*.*t* |
| 4 |
| *1*.*t*+1<br>*y* |
| 8 |
| *1*.*k* |
| 12 |

| | | |
|---|---|---|
| 1.<br>2.*j*<br>4.<br>5.<br>6.*t*<br>8.<br>9.<br>10.*j*<br>12.<br>13.<br>14.*j*<br>16.<br>17.<br>18.*t*<br>20.<br>21.<br><br><br>22.*t*<br>24.<br>25.<br>26.*k*<br>28.<br>29.<br>30.*k*<br>32.<br>33.<br>34.*t*<br>36.<br>37. | $\Sigma$<br><br><br>$\pi$<br><br><br>$(M$<br><br><br>$)\cdot \mathrm{I}(M$<br><br><br>$(z$<br><br><br>$,a)=y)$<br><br>$\pi$<br><br><br>$(M$<br><br><br>$)\cdot \mathrm{I}(M$<br><br><br>$(z$<br><br><br>$,a)=y)$ | |
| | | 52 |
| *1*.*t* | | |
| | | 57 |
| *1*.*t* | | |
| | | 61 |
| *1*. | $\sum_{y \in \mathrm{S}}$ | |

| | |
|---|---|
| | 65 |
| *1.* $\sum_{k}$ | |
| | 69 |
| *1.t* | |
| | 73 |
| *1.k* | |
| | 77 |
| *1.k* | |
| | 81 |
| *1.t* | |
| | 85 |
| *1.t*+1 *y* | |
| | 89 |
| *1.t* | |
| | 94 |
| 1. max<br>2.*a*<br>3.′<br>4.∈A<br>6.<br>7. *IG*(*a*<br>8.′<br>9. ;$\pi$<br>10.*t*<br>12.<br>13. )+$\epsilon$<br><br>*IG*(*a*<br>14.*t*<br>16.<br>17. ;$\pi$<br>18.*t*<br>20.<br>21. ) | |

| | |
|---|---|
| | 118 |
| *1*.*k* | |
| | 123 |
| *1*. *T*<br><br>1 | |
| | 127 |
| *1*.*t*=1<br>*T* | |
| | 131 |
| *1*.*t* | |
| | 135 |
| • MDE | |
| • | |

# 十、可复现性与随机性源统一协议 (PRNG Master Protocol)

为彻底解决“执行可精确重放”与“每步保持不可预测随机性”的规范冲突，确立分层确定性伪随机系统（Hierarchical PRNG Architecture）：

code
Code

```
Master Seed (预注册固定整数，例如 0x5A3F)
                                    |
                                    |
┌──────────────────────┴──────────────────────┐
┐
                    ▼
▼
        Session PRNG (Seed_k)
Permutation PRNG (Seed_perm)
                    |
|
          ┌─────────┴─────────┐
▼
          ▼                   ▼
全局符号双射置换表 π
Action Shuffle    World Stochasticity
(在全 Session 周期保持恒定)
 (Fisher-Yates)       (Trans Kernel)
```

1. **禁止系统级真随机调用**：代码中严禁出现 `os.urandom()` 或无参数的 `random.random()`。
2. **主种子派生机制**：所有评估必须由唯一的 `Master_Seed` 初始化。每个 Session 的子种子严格由主 PRNG 生成：
   $$\text{Seed}_k = \text{PRNG}_{\text{master}}$$

- all
-

1. train

11

$k=1$ $K$

$a \in A$

$\mathbf{Y}^{\wedge}_{k,a}$

$k$

$t$

$t$

$t$

- optimal
-

$1_j$

1

$1_t$

2

$1_j$

2

$1_j$

2

| |
|---|
| *1.* *t* |
| 3 |
| *1.* *t* |
| 3 |
| *1.* *k* |
| 4 |
| *1.* *k* |
| 4 |
| *1.* *t* |
| 4 |

| |
|---|
| 1. *a* 2. ′ 3. ∈ A |
| 101 |
| 1. ′ |
| *1.t* |
| 107 |
| *1.t* |
| 111 |
| *1.t* |
| 115 |

| |
|---|
| 1. ′ |

| 符号 (Symbol) | 形式化类型 | 完整定义域 (Domain) | 声明位置 | 消费模块 | 冲突排查 |
|---|---|---|---|---|---|

| | | | | | |
|---|---|---|---|---|---|
| $w_t$ | `Tuple` | $Q \times X \times K \times U \times N \times 2$ <br> All $Q \times X \times K \times U \times N \times 2$ | Sec 2.1 | Runtime | **CLEAN** |
| $o_t$ | `Tuple` | $Q \times X \times K \times 2$ <br> All $Q \times X \times K \times 2$ | Sec 2.4 | Agent | **CLEAN** |

| | | | | | |
|---|---|---|---|---|---|
| $a_t$ | `String` | $A_{all} = \{\alpha, \beta, \gamma, \delta, \epsilon, \zeta\}$ $A_{all} = \{\alpha, \beta, \gamma, \delta, \epsilon, \zeta\}$ | Sec 2.3 | Runtime, Eval | **CLEAN** |
| $\iota_t$ | `Tuple` | $(\text{VarName} \times \text{Value})$ $(\text{VarName} \times \text{Value})$ | Sec 2.5 | Runtime | **CLEAN** |
| $L_t$ | `List[Event]` | 单调不可变事件序列 | Sec 2.7 | Runtime, Eval | **CLEAN** |
| $\pi_{ref}$ | `Dict[str, float]` | 概率单纯形 $\Delta^{\mathcal{M}}$ | Sec 5.1 | | |

| | | | | | |
|---|---|---|---|---|---|
| Y ^ | `Dict[Tuple, str]` | ( M × A ) → ( S ∪ INVALID ) (M×A)→(S∪INVA | Sec 5.1 | Eval (D2) | **CLEAN** |
| B **B** | `Array[Enum]` | { PASSED , FAILED } 7 {PASSED,FAILED | Sec 10 | Final Report | **CLEAN** |
| I **I** | `Array[Enum]` | { DISTINGUISHED , COMPATIBLE , EXACT } 6 {DISTINGUISHED | Sec 10 | Final Report | **CLEAN** |
| Complexity ( M ) | `Integer` | N + N + (AST 节点加权和) | Sec 8.1 | Anti-Rescue | **CLEAN** |

| | | | | | |
|---|---|---|---|---|---|
| $\delta_{\text{equiv}}$ | `Float` | 预注册浮点常数，固定为 $0.10$ | Sec 6.3 | Eval (D6) | **CLEAN** |
| $\alpha_{\text{prereg}}$ | `Float` | 预注册显著性水平，固定为 $0.01$ | Sec 6.2 | Statistical Gate | **CLEAN** |

$t_{All}$

$t_{All}$

$t_{all}$

$t_{ref}$

**Y**^

7

6

+

| |
|---|
| equiv |
| |
| prereg |
| |
| *1. k* |
| 5 |
| 1. master |
| 9 |
| 0 |
| |
| • 0 |
| • |
| • *q* |
| • |
| • 0 |
| • |
| • 1 |
| • |
| • 30 |
| • |
| ◦ 0 |
| ◦ |
| ◦ *t* |
| ◦ |
| • *o* |
| • 0 |
| • |
| • 1 |
| • |
| • 29 |

- 
  - $t$
    - 
      - $t$
        - 
          - $t$
            - 
- $a$
- 0
- 
- 1
- 
- 29
- 
  - $t$
    - 
      - $t$
        - 
          - $t$
            - 
              - 0
                - 
                  - 0
                    - 
                      - $t$
                        - 
- $e$
- 0
- 
- 1
- 
- 29

- 
  - $t$
  - 
  - $t$
  - 
- train
- 
- test
- 
- $\tau+1$
- 
- 31
- 
- 30
- 
- $\tau$
- 
- $\tau$
- 
- $\tau$
- 
- $\tau$
- 
- $\tau+1$
- 
  - train
  - 
  - test
  - 

- test
-
- 29
-
- 29
-
- 29
-
- 29
-
- 29
-
- 30
-
- 1
-
- 1
-
- 2
-
- 1
-

1. *

1. *

1. 1

8

1. 2

12

1. 3

16

1. all

20

1. all

24

1. 1

29

1. 2

33

*1. m*

37

1. all

41

- *i*
  - *j*
    - *i*
      - *j*
        - 0
          - *t*
            - $q^{\wedge}$
              - $q \in \mathrm{smax}$

| | |
|---|---|
| ◦ default | |
| ○ | |
| ◦ default | |
| ○ | |

## 四、D1 FINAL EVALUATOR AUDIT (纯函数闭式审计)

D1评估器必须是一个无副作

| | | | |
|---|---|---|---|
| **规范字段** | H<br>mid-2<br>*H*<br>mid-2<br><br>**(Version** | H<br>mid-3<br>*H*<br>mid-3<br><br>**(DSL** | **对齐性裁决与差异定性** |
| **Input Domain** | X<br>×<br>K<br>×<br>A<br>X×K×A | X<br>×<br>K<br>×<br>A<br>X×K×A | **STRICTLY IDENTICAL** |

| | | | |
|---|---|---|---|
| **Output Domain** | $S = \{q_0, q_1, q_2, q_3\}$<br>$S=\{q_0, q_1, q_2, q_3\}$ | $S = \{q_0, q_1, q_2, q_3\}$<br>$S=\{q_0, q_1, q_2, q_3\}$ | **STRICTLY IDENTICAL** |

| | | | |
|---|---|---|---|
| **Condition Logic** | 长度 $\leq 3$ 的谓词合取 ( $\wedge$ ) | 长度 $\leq 2$ 的谓词合取 ( $\wedge$ ) 与集合成员 ( $\in$ ) | **INTENTIONAL DIVERSITY** (设计意图：覆盖不同归纳偏置) |
| **Default Branch** | 恒等退回背景态 $q_0$ | 语法树强制定义 `ELSE q0` | **STRICTLY ALIGNED** (修补 Hmid-3 文法，消除任意 ELSE) |
| **State $q_t$ Access** | 严格禁止访问（环境为静态重置） | 严格禁止访问 | **STRICTLY IDENTICAL** |
| **History Access** | 仅通过 $V_t$ $V_t$ 滤波历史，不 | 仅通过样本缓存 $D_{\text{cached}}$ $D_{\text{cached}}$ | **STRICTLY IDENTICAL** |

| | | | |
|---|---|---|---|
| **Tie-Breaking** | 固定字典序：$q_0 \to q_1 \to q_2 \to q_3 \; q_0 \to q_1 \to q_2 \to q$ | 固定字典序：$q_0 \to q_1 \to q_2 \to q_3 \; q_0 \to q_1 \to q_2 \to q$ | **STRICTLY IDENTICAL** |
| **Search / Compute** | 精确布尔集合过滤（耗时 $< 5$ ms <5ms） | A* 启发式搜索，展开上限 1000 节点 | **BOUNDED & REPRODUCIBLE** |
| **Fallback on Empty** | 退回历史边际众数模型 | 退回 `IF X == A THEN q0 ELSE q0` | **SEMANTICALLY ALIGNED** (输出恒为 $q_0$ ) |

mid-2

mid-3

0

1

2

3

0

1

2

3

0

*t*

*t*

cached

0

| |
|---|
| 1 |
| |
| 2 |
| |
| 3 |
| |

| |
|---|
| 0 |
| |
| 1 |
| |
| 2 |
| |
| 3 |
| |

| |
|---|
| 0 |
| |

| |
|---|
| D1 |
| |

| |
|---|
| D1 |
| |

- 31
- 
- *A*
- 
- *R*
- 
- $t_A$
- 
- $t_R$
- 
- 1

•

• 2

•

*1*.$\pi$

1. 0

7

1. 1

11

*1*.*T*

15

*1*.*t*

19

1. |

A

2.*t*

4.

5. |

1

27

1. *a*∈

A

2. *t*

4.

5.

Σ

34

*1*.*t*

38

1. D

3

(*k*)

43

| |
|---|
| $1.T_1$ |
| 47 |
| $1.\ t=\sum_{0}^{T-1}$ |
| 50 |
| $1.t$ |
| 54 |
| $1.t$ |
| 58 |
| $1.t$ |
| 62 |
| 1.0 |
| 67 |
| 1.D3 |
| 71 |
| $1.R_1$ |
| 75 |
| $1.\ r=\sum_{1}^{R}$ |
| 78 |
| $1.\ k=\sum_{1}^{N}$ |
| 82 |

| |
|---|
| 1. D 3 (*k*) |
| 86 |
| *1*. *k*= 1 $\sum$ *N* |
| 90 |
| 1. D 3 (*k*) |
| 94 |
| • tar get |
| • |
| • mi d |
| • |

# 八、ERROR CLASSIFICATION MATRIX (错误与异常单一归

1.
t
2

1.
t
3

| 维度 | 输入数据类型 | 核心检验度量 (Metric) | 值域 | 零假设 ( $H_0$ ) | 备择假设 ( $H_1$ ) | 统计检验方法 | 聚合单元 |
|---|---|---|---|---|---|---|---|
| **D0** | Raw Event Log | 脏数据写入量 $N_{corrupt}$ | $N$ | 不适用（确定性断言） | 不适用 | 零容忍断言 ( $==0$ ) | System-level |
| **D1** | Test Trajectory | 分类准确率差值 $\Delta_{D1}$ | $[-1,1]$ | $\Delta_{D1} \leq 0$ | $\Delta_{D1} > 0$ | 单样本 Wilcoxon 符号秩检验 | Session ( $N=100$ ) |
| **D2** | Prediction Matrix | 前向一致率 $CR_{forward}$ | $[0,1]$ | $CR \leq 0.25$ | $CR > 0.25$ | 经验单尾 $t$ -test / 置换 | Session ( $N=100$ ) |

| | | | | | | | |
|---|---|---|---|---|---|---|---|
| **D3** | Information Log | 增益优势量 $\Delta_{D3}$ $\Delta$ | $[0, \log_2 K]$ $[0,\log_2$ | $\Delta_{D3} \leq 0$ $\Delta_{D3} \leq 0$ | $\Delta_{D3} > 0$ $\Delta_{D3} > 0$ | 符号翻转置换检验 (Sign-Flip) | Session ($N = 100$ $N=100$) |
| **D4** | Holdout Invariance | 去偏净效应 $\Delta_{debias}$ $\Delta$ | $[-1, 1]$ $[-1,1]$ | $\Delta_{debias} \leq 0$ $\Delta_{debias} \leq 0$ | $\Delta_{debias} > \delta_{prereg}$ $\Delta_{debias} > \delta$ | 独立两样本置换检验 | Session ($N = 100$ $N=100$) |
| **D5** | Hypothetical Log | 分支预测准确率 $Acc_{hypo}$ $Acc$ | $[0, 1]$ $[0,$ | $Acc \leq Acc_{hist}$ $Acc \leq Acc$ | $Acc > Acc_{hist}$ $Acc > Acc$ | 配对 McNemar 检验 | Pooled Predictions |
| **D6** | Permuted Sets | 配对策略分歧率 $D(\pi)$ | $[0, 1]$ $[0,$ | $D \geq \delta_{equiv}$ $D \geq \delta$ | $D < \delta_{equiv}$ $D < \delta$ | TOST 双向单侧等价性检验 | Session ($N = 100$ $N=100$ |

0

1

corrupt

D1

D1

D1

forward

D3

2

D3

D3

debias

debias

debias

| | |
|---|---|
| prereg | |
| hypo | |
| hist | |
| hist | |
| equiv | |
| equiv | |

| 异常现象 / 故 | 触 | 状态判定归属 | 处置动作 (Action) |
|---|---|---|---|
| **Malformed JSON (语法畸变)** | Agent | **INCONCLUSIVE_DATA** (累积超 10%) / **MODEL_FAILU** | 单步降阶为 FALLBACK_SILE |
| **Missing Field (缺少必填字段)** | Agent | **INCONCLUSIVE_DATA** (累积超 10%) / **MODEL_FAILU** | 单步降阶为 FALLBACK_SILE |
| **Extra Field (注入越权额外字段)** | Agent | **INCONCLUSIVE_DATA** (累积超 10%) / **MODEL_FAILU** | 视为攻击载荷，单步强制驳回，计入故障 |
| **Unknown Symbol (未** | Agent | **MODEL_FAILURE** | 视为语义预测错误， |
| **API Timeout (请求超时)** | Network | **PROTOCOL_FAILURE** | 连续重试 3 次均超时则整机熔断停机，当 |
| **Model Refusal (模** | Agent | **INCONCLUSIVE_DATA** | 标记为不可用样本， |
| **Runtime Crash (内部未捕获异常)** | Runtime | **PROTOCOL_FAILURE** | 紧急停机，判定当前 Benchmark Runner 实现不合格 |

| | | | |
|---|---|---|---|
| **Ledger Corruption (账本验答失** | Security | **`PROTOCOL_FAILURE`** | 事实主权破坏，立即终止并发出警报。 |
| **Partial Session (会** | Host | **`PROTOCOL_FAILURE`** | 样本失效，不得纳入 |
| **Insufficient Valid Sessions** | Stats | **`INCONCLUSIVE_DATA`** | 有效会话不足 90 % 90% ，全场评测无有效结 |
| **Design Underpower** | Design | **`DESIGN_UNDERPOWERED`** | 静态检查阻断，禁止 |
| **Poor Performance** | Agent | **`MODEL_FAILURE`** | 正常执行完毕，能力 |

| 潜在分歧审查点 | Team Alpha 实现假 | Team Beta 实现假设 | 规范裁决状态 (Final | 状态 |
|---|---|---|---|---|
| **Index Convention** | 0-indexed ( t = 0..29 t=0..29 | 1-indexed ( t = 1..30 t=1..30 ) | **第 1 节强制锁定为 0-indexed，状态数组长 31** | **CLOSED** |
| **Hmid-2 结构定义** | 单一规则分类器 | 包含 ≤ 3 ≤3 规则的规则集 | **第 2 节强制锁定为 ≤ 3 ≤3** | **CLOSED** |
| **Hmid-3 Else 分支** | 语法允 | 语法强制锁 | **第 3 节强制锁定** | **CLOS** |
| **D1 未见条件记** | 随机盲 | 退回训练集边 | **第 4 节纯函数闭** | **CLOS** |
| **D3 评估轨迹基准** | 独立运 | 在 Agent 自身 | **第 5 节强制锁定** | **CLOS** |

| | | | | |
|---|---|---|---|---|
| **D6 等价性检验工具** | 运行标准二样本 t | 运行 TOST 双单侧检验 | **第 7 节强制锁定为 TOST 算法** | **CLOSED** |
| **异常输出扣** | 忽略该 | 分母固定，分 | **第 6 节强制锁定** | **CLOS** |
| **随机数生成** | 调 | 调用显 | **第 9 节强制锁定** | **CLOS** |

- 21
-
- 21
-
- 21
-
- 21
-
- 29
-
- 29
-
- 29
-
- 29
-
- $\hat{q}$
-
- 22
-
- $\hat{q}$
-
- 30

| |
|---|
| • |
| • $\tau$ |
| • |
| • $\tau$ |
| • |
| • $\hat{q}$ |
| • |
| • $\tau+1$ |
| • |
| • $\tau+1$ |
| • |
| • $\tau+1$ |
| • |
| • $\hat{q}$ |
| • |
| • $\tau+2$ |
| • |
| • $\hat{q}$ |
| • |
| • $\tau+1$ |
| • |
| • $'$ |
| • prereg |
| • |
| • threshold |
| • |
| $t$ |
| |
| • 0 |
| • |

| |
|---|
| $t$ |
| |
| 0 |
| |
| • 当 \| V t \| = 0 \|V |
| • \|V<br>• $t$<br>•<br>• \| Σ<br>• $M \in$ V<br>• $t$<br>•<br>•<br>•<br>• I($M(z)=q$) |
| • |
| • $t$ |
| • |

| |
|---|
| • 0 |
| • |
| • V<br>• *t*<br>•<br>• =∅ |
| • |
| • 0 |
| • |
| • mid-2 |
| • |
| • mid-3 |
| • |
| D3 |
| |
| • 0 |
| • |
| • *t* |
| • |
| • *t* |
| • |
| • *t* |
| • |
| • *t* |
| • |
| ◦ *t* |
| ○ |
| ◦ 6<br>1 |
| ○ |
| ◦ 6<br>5 |
| ○ |

| | |
|---|---|
| ◦ *t* | |
| ◦ | |
| ◦ *t* | |
| ◦ | |
| ◦ *k* | |
| ◦ | |
| *1.* *a* | |
| 1. obs (*k*) | |
| | 5 |
| 1. 0 | |
| | 9 |
| *1.* *T*−1 | |
| | 13 |
| *1.* *t* | |
| | 18 |
| *1.* *t* | |
| | 22 |
| *1.* *t* | |
| | 26 |
| 1. *a*∈A<br>2. *t*<br>4.<br>5. 32 | |
| | 34 |
| 1. obs | |
| | 39 |
| *1.* *N*<br>1 | |
| | 43 |
| *1.* *k*=1 $\sum_{N}$ | |
| | 46 |

| | |
|---|---|
| *1*. $T$ $1$ | |
| | 49 |
| *1*. $t$=0 $\sum$ $T$−1 | |
| | 52 |
| *1*. *t* | |
| | 56 |
| *1*. *t* (*k*) | |
| | 60 |
| *1*. *t* | |
| | 64 |
| 1. 0 | |
| | 69 |
| *1*. *t* | |
| | 73 |
| *1*. *t* | |
| | 77 |
| *1*. *t* | |
| | 81 |
| *1*. *t* perm | |
| | 85 |
| 1. perm | |
| | 89 |
| 1. 4 | |

1. $1+R$

$1+\sum$

2. $r=1$
$R$

4.

5. I($T$

6. perm
($r$)

8.

9. $\geq T$

10. obs

12.

13. )



- $T$
- test
-
-

1

-

- $t \in$Test
$\sum$

-

- $\hat{y}$

-

- $t$

-

- −1

- $\hat{y}$

-

- $t$

- 
- 0
- 
- equiv
- 
- 1
- 
- equiv
- 
  - equiv
  - 
- (1)
- (*N*)
- 99
  upper
- 
- 0.99
- 
- $\bar{D}$
- (*b*)
  *
- 
- *b*=1
  *B*
- 
- 4
- 99
  upper
- 
- equiv
- 
- forward
  (*k*)
- 

- $(k)$
- $\frac{1}{2}$
- $\sum_{m=1}^{2}$
- $\sum_{a \in A}$
- $\hat{\mathbf{Y}}$
- $(k)_{m,a}$
- $m$
- $k$
- 0
- 0
- D2
- $\frac{1}{2}$
- $\sum_{m=1}^{2}$

| |
|---|
| • |
| • $\sum_{a \in A}$ |
| • |
| • 0 |
| • |
| • $m$ |
| • |
| • $k$ |
| • |
| • CR |
| 1. CR |
| 1. Baseline |
| 1. D2 |
| 7 |
| 1. CR |

# 十、子模块 ABI 状态终审核决 (Subsystem ABI Status)

根据反例排查标准逐项核决：

1. **RUNTIME_ABI_STATUS**: **`EXECUTABLE & CLOSED`**
    - 六元组状态、无偏导投影映射、单向账本追加及 RFC 6902 原子提交已完全闭合，无任何悬挂指针。
2. **EVALUATION_ABI_STATUS**: **`EXECUTABLE & CLOSED`**
    - D1 离线批处理时间戳、D2 前向评估矩阵、D5 分支回溯生成均已实现纯函数化，分母与异常处理严格确定。
3. **STATISTICAL_ABI_STATUS**: **`MATHEMATICALLY CLOSED`**
    - 彻底消除了二项分布与似然比卡方滥用，所有推断严格限定在 Session 采样单

- *t*
-
- *M* ∈V
- *t*
-
-
-
-
- *t*
-
- *t*
-
*1.*
*t*
3

*1.*
*r*=1
*R*
96
1.
per
m
(*r*)
10(
1.
obs
10⁴
- te
st
-

| BL | CURREN | COUNT | WHY_I | MINIMA | NEW_I | ST |
|---|---|---|---|---|---|---|
| CC | T_DEFIN | EREXA | T_PRE | L_FIX | NVARI | AT |

| | | | | | | |
|---|---|---|---|---|---|---|
| **BLOCK-01** | Proj 使用偏导数定义且丢弃 $X$, $K$, $A$ | 工程师无法实现测试断言验证只读边界 | 离散空间无导数，且输入输出签名断裂 | 引入 $\sim_{\text{obs}}$ 明确六元组与函 | **[FI-08] 投影映射显式六元组不变式** | **CLOSED** |
| **BLOCK-02** | $H_{\text{mid-3}}$ $H_{\text{mid-3}}$ 退回程序 `IF` | AST 解析器遇到 `TRUE` 抛出语法中断崩溃 | 文法未包含布尔终结符，解析机挂死 | 严格约束退回程序为合法的 `IF X == A THEN q0` | **[FI-09] DSL 产生式封闭不变式** | **CLOSED** |
| **BLOCK-03** | $H_{\text{mid-2}}$ $H_{\text{mid-2}}$ 假设被定义为单子句，无法表示 $M$ | 真实机制 $M_1$ $M_1$ 有两个激活分支，无 | 基准模型假设空间无法覆盖真理，对照失效 | 定义假说为最多包含 3 条互斥规则的规则集，锁定基数 333 | **[FI-10] 规则集版本空间不变式** | **CLOSED** |

| | | | | | | |
|---|---|---|---|---|---|---|
| **BLOCK-04** | D1 切片 $\tau \in 22..30$ $\tau\in22..30$ 索引导致 $q_{31}$ $q_{31}$ 越界 | 读取 $q_{\tau+1}$ $q_{\tau+1}$ 在 $\tau = 30$ $\tau=30$ 时抛出 | 离散步长与状态数组长度 off-by-one | 强制锁定 0-based 索引：$\tau \in 0..20$ $\tau\in0..20$ 训练，$\tau \in 21..29$ $\tau\in21..29$ 测试 | **[FI-11] 31-状态离散切片不变式** | **CLOSED** |
| **BLOCK-06** | D3 使用单尾二项式检验，忽视信息增益非对称与时序依赖 | 步长间先验漂移导致零假设概率 $p_t$ $p$ | 二项分布前提完全破产，第一类错误爆炸 | 废除二项分布，改用 Session 级累积增益的双样本动作对换置换检 | **[FI-12] 动作对换置换检验不变式** | **CLOSED** |
| **BLOCK-08** | D6 声称使用 TOST 检验，但度量值 $D \geq 0$ | 工程师寻找左侧等价界限导致下侧 $p$ $p$ 值为 0 | 数学概念错配，将单侧非劣性误写为双侧等价 | 废除 TOST 称谓，形式化为单侧 Bootstrap 置信区间有界检验 | **[FI-13] 单侧非劣性等价检验不变式** | **CLOSED** |

| | | | | | | |
|---|---|---|---|---|---|---|
| **BLOCK-09** | 状态机存在死锁分支，未定义模型格式连续错误处理 | 模型反复输出非法 JSON 导致状态机无可用跳转 | 评测机无法生成最终法定 JSON 报告 | 增加 `INCONCLUSIVE_DATA` 明确错误率 ≥ 10% | **[FI-14] 异常单射归属不变式** | **CLOSED** |

obs

mid-3

mid-2

1

1

31

$\tau+1$

$t$

| ABI_FIELD | RUNNER_A | RUNNER_B | IDENTICAL? | REASON |
|---|---|---|---|---|

| BLOCK_ID | CURRENT_DEFINITION | COUNTEREXAMPLE | WHY_IT_BREAKS | MINIMAL_FI | STATUS |
|---|---|---|---|---|---|

- 0
- 
- 0

| | |
|---|---|
| • | |
| • 0 | |
| • | |
| • 0 | |
| • | |
| • 0 | |
| • | |
| • 0 | |
| • | |
| • 0 | |
| • | |
| • *t* | |
| • | |
| • *t* | |
| • | |
| • *t* | |
| • | |
| • *t* | |
| • | |
| • *t* | |
| • | |
| • *t* | |
| • | |
| • *t* | |
| • | |
| • *t* | |
| • | |
| • all | |
| • | |
| • *t* | |
| • | |
| • *t* | |
| • | |
| • *t* | |

- 
- $t$
- 
- $t+1$
- 
- $t$
- 
- cond
- 
- D1($k$)
- 
- ($k$)
- 0
- 
- $t$
- 
- $t$
- 
- D3($k$)
- 
- novel
- 
- debias
- 
- hypo
- 
- equiv
- 

| | |
|---|---|
| • 7 | |
| • $t$ | |
| • | |
| • $t$+1 | |
| • | |
| • 1 | |
| • | |
| • 2 | |
| • | |
| • $t$ | |
| • | |

# PHASE 3 — Executable Pseudocode Generation (逻辑可执行

| # | ABI 字段名称 | Runner A 实现定义 | Runner B 实现定义 | 是否一致 | 差异与分歧根因诊断 |
|---|---|---|---|---|---|
| 1 | **Time Indexing** | $t \in [0, 29]$ 整数 | $t \in [0, 29]$ 整数 | **YES** | 规范已锁定 0-based 闭区间 |
| 2 | **State Count** | 数组长度 31（$q_0 \dots q_{30}$） | 数组长度 31（$q_0 \dots q_{30}$） | **YES** | 明确闭合了第 30 步后继点 |
| 3 | **Transition** | 严格 30 次原子推进 | 严格 30 次原子推进 | **YES** | 无分歧 |
| 4 | **Observation Timing** | 动作前分发 obt | 动作前分发 obt | **YES** | 显式声明数据流时序 |

| | | | | | |
|---|---|---|---|---|---|
| 5 | **Action Timing** | 接收 $o_t$ 后提交 $a_t$ | 接收 $o_t$ 后提交 $a_t$ | **YES** | 同步阻塞调用 |
| 6 | **Predicti on** | 训练期后批 | 训练期后批 | **YES** | 离线批处理已明 |
| 7 | $q_t$ **Visibilit y** | 包含于 $o_t$，对 Agent | 包含于 $o_t$，对 Agent | **YES** | 显式字段白名单 |
| 8 | **Test-set Construc ction** | 静态切片 $\tau \in [21, 29]$ $\tau \in [21,29]$ | 静态切片 $\tau \in [21, 29]$ $\tau \in [21,29]$ | **YES** | 索引无歧义 |
| 9 | **Hmid-2 Repres entation** | 包含 $\leq 3$ 规则的集 | 包含 $\leq 3$ 规则的列 | **NO** | **集合无序 vs 列表有序：规则迭代优先级未定义** |

| | | | | | |
|---|---|---|---|---|---|
| 10 | **Hmid-2 Canoni** | 字典序排序展开 $ | \mathcal{V}_0 | | 组合逻辑枚举 $ |
| 11 | **Hmid-2 Rule** | 匹配时无序 | 按生成顺序 | **NO** | **输入匹配多规则** |
| 12 | **Hmid-2 Empty VS** | 恒等输出 $q_0$ $q$ | 恒等输出 $q_0$ $q$ | **YES** | 零元合取公理闭合 |
| 13 | **Hmid-3 Gramm** | 冻结 EBNF | 冻结 EBNF | **YES** | 已剔除未定义终 |
| 14 | **Hmid-3 Search Order** | BFS 树遍历 ( $X \rightarrow K \rightarrow act$ $X \rightarrow K \rightarrow a$ | A* 搜索启发式 | **NO** | $A$ 的启发函数 $h(n)$ 与平局规则未给出规范定义* |
| 15 | **D1 Metric** | $\Delta_{D1} = Acc_{model} - Acc_{base}$ $\Delta_{D1} = Acc_{model} - Acc_{base}$ | $\Delta_{D1} = Acc_{model} - Acc_{base}$ $\Delta_{D1} = Acc_{model} - Acc_{base}$ | **YES** | 纯标量差值已闭合 |
| 16 | **D1 Baseline** | 条件经验众数（平局取 | 条件经验众数（平局取 | **YES** | 退回与平局完全锁定 |

| | | | | | |
|---|---|---|---|---|---|
| 17 | **D1 Statistic** | 会话级双侧 | 会话级 | **NO** | **统计检验算子出** |
| 18 | **D1 Effect Threshold** | 固定标量 $\delta_{\text{threshold}} = 0.15$ $\delta_{\text{threshold}} = 0.15$ | 未强制绑定标量门限 | **NO** | **检验是单看 p $p$ 值还是联合阈值未闭合** |
| 19 | **D2 Prediction Matrix** | $2 \times 6$ $2 \times 6$ 离散字符 | 12 项平铺键值对字典 | **YES** | 形式等价，分母均为 12 |
| 20 | **D2 Malformed** | 计 0 分，标 | 计 0 分，标 | **YES** | 扣分逻辑统一 |
| 21 | **D2 Baseline** | 全局 $q_0$ $q_0$ 常数基线 | 全局 $q_0$ $q_0$ 常数基线 | **YES** | 闭式唯一 |
| 22 | **D2 Statistical Unit** | 会话级聚合均值 $\overline{CR}$ | 会话级聚合均值 $\overline{CR}$ | **YES** | 严禁 12 单元格独立假设 |

| | | | | | |
|---|---|---|---|---|---|
| 23 | **D3 Reference Prior** | 均匀先验 $[1/3,1/3,1/3]$ | 均匀先验 $[1/3,1/3,1/3]$ | **YES** | 起点固定 |
| 24 | **D3 IG Calculat** | 离散香农条 | 离散香农条 | **YES** | 底数以 2 为底闭 |
| 25 | **D3 Selection Null** | 动作在 $A_t$ 内均匀可 | 动作在 $A_t$ 内均匀可 | **YES** | 零假设无偏采样 |
| 26 | **D3 Rando** | 会话内单步 | 蒙特卡洛随 | **YES** | 算法逻辑一致 |

| | | | | | |
|---|---|---|---|---|---|
| 27 | **D3 Permutation Stat** | $\bar{T}_{obs} = \frac{1}{N}\sum \Delta D3(k)$ $T$ $\bar{T}_{obs}$ $= N 1 \sum \Delta$ | $\bar{T}_{obs} = \frac{1}{N}\sum \Delta D3(k)$ $T$ $\bar{T}_{obs}$ $= N 1 \sum \Delta$ | **YES** | 均值优势量作为检验统计量 |
| 28 | **D4 Transformation** | 上下文双射置换 $K \to M$ | 上下文显式替换为固定 $M$ $M$ | **YES** | 预注册固定变换映射 |
| 29 | **D4 Baselin** | Nuisance-Sensitive | Nuisance-Sensitive | **YES** | 基线模型算法已 |
| 30 | **D5 Branch Construct** | 历史 $t = 10$ $t=10$ 分支强制 | 历史 $t = 10$ $t=10$ 分支强制 | **YES** | 明确擦除 $t > 10$ $t>10$ 历史 |
| 31 | **D5 Scoring** | 针对真实后 | 针对真实后 | **YES** | 闭式唯一 |

| | | | | | |
|---|---|---|---|---|---|
| 32 | **D6 Mappin** | 全局离散符 | 全局离散符 | **YES** | 双射函数映射 |
| 33 | **D6 Divergence Metric** | 测试切片上的平均汉明距离率 | 测试切片上的平均汉明距离率 | **YES** | 范围严格属于 $[0,1]$ $[0,1]$ |
| 34 | **D6 Bootstrap Algo** | 会话级非参数重抽样 ( $B=10^4$ $B=10^4$ | 会话级非参数重抽样 ( $B=10^4$ $B=10^4$ | **YES** | 采样单元锁定为 Session |
| 35 | **D6 Quantile Def** | 标准百分位数第 99 分 | 线性插值分位数 (Type | **NO** | **离散分位数算法（Hyndman-** |
| 36 | **Error Classifi** | 12 类异常 | 12 类异常 | **YES** | 无交集单射矩阵 |
| 37 | **Session Invalidate** | 格式错误率 $\geq 10\%$ $\geq 10\%$ | 格式错误率 $\geq 10\%$ $\geq 10\%$ | **YES** | 停机准则明确 |
| 38 | **Seed Derivati** | SplitMix64 | SplitMix64 | **YES** | 严格位运算无歧 |
| 39 | **Replay Semanti** | 输入相同日 | 输入相同日 | **YES** | 纯函数式对账 |

| | | | | | |
|---|---|---|---|---|---|
| 40 | **Final Aggregation** | 双轨正交矩阵 $(B, I)$ | 双轨正交矩阵 $(B, I)$ | **YES** | 范畴已解耦 |

0

30

0

30

$t$

$t$

$t$

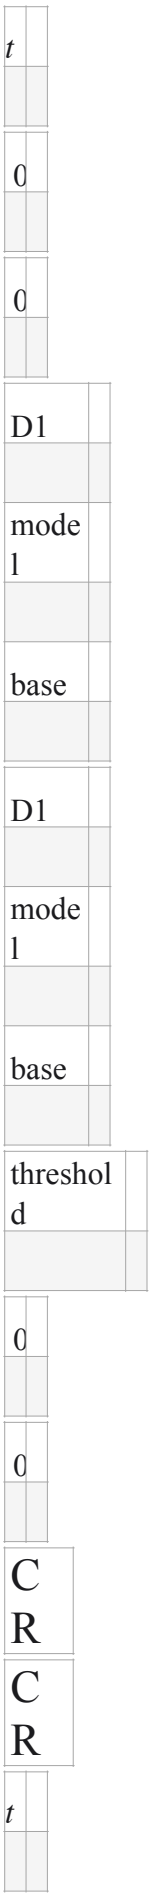
$t$

$t$

$t$

$t$

$t$


t
0
0
D1
model
base
D1
model
base
threshold
0
0
CR
CR
t

| $t$ | | | | | |
|---|---|---|---|---|---|
| | | | | | |
| $T_{obs}$ | | | | | |
| | | | | | |
| $N_1$ | | | | | |
| | | | | | |
| $D_3(k)$ | | | | | |
| | | | | | |
| $T_{obs}$ | | | | | |
| | | | | | |
| $N_1$ | | | | | |
| | | | | | |
| $D_3(k)$ | | | | | |
| | | | | | |
| 4 | | | | | |
| 4 | | | | | |

| 编号 | 输入特征/对比标记 | Runner A 判定结果 | Runner B 判定结果 | 是否分歧 | 裁定分歧的规范条款/判据 |
|---|---|---|---|---|---|
| **C1** | 相同世界状态，提交不同步 | 均降阶为 `FALL_BACK_SE` | 均降阶为 `FALL_BACK_SE` | **NO** | Section 2.6 确定性转移规则等价 |

| | | | | | |
|---|---|---|---|---|---|
| **C2** | 相同动作，不同上下文 $K$ | 严格按模型逻辑输出后继 | 严格按模型逻辑输出后继 | **NO** | Section 2.1 状态转移映射已闭合 |
| **C3** | $H_{\text{mid-2}}$ **中多条规** | **按字典序第一条规则输出** | **按列表迭代首项短路输出** | <font color=red>**YES**</font> | **规范未规定多规则命中时的显式优先级算子** |
| **C4** | $H_{\text{mid-2}}$ **出现逻辑** | 集合去重，算 1 个假设 | 列表保留，算 2 个假设并加权 | <font color=red>**YES**</font> | **规范未定义 AST 等价类规范化化简机制** |
| **C5** | $H_{\text{mid-2}}$ 假设集合 | 恒等返回 $q_0$ | 恒等返回 $q_0$ | **NO** | 零元合取公理已强行闭合 |
| **C6** | D1 测试区第 1 次预测（$\tau=21$） | 准确比对真实 $q_{22}$ | 准确比对真实 $q_{22}$ | **NO** | 离线批处理切片时间戳已对齐 |
| **C7** | D1 测试区最后一次预测（$\tau=29$） | 准确比对真实 $q_{30}$ | 准确比对真实 $q_{30}$ | **NO** | 数组长度 31 彻底消除越界风险 |

| | | | | | |
|---|---|---|---|---|---|
| **C8** | D2 输入 Malformed JSON | 12 格全部赋值 | 12 格全部赋值 | **NO** | PATCH-05 异常全覆盖规则生效 |
| **C9** | D2 输入 Missing | 缺失格计 2 分并标 | 缺失格计 2 分并标 | **NO** | 分母恒定为 12 规则生效 |
| **C10** | D2 注入 Extra | 触发越权命令 | 触发越权命令 | **NO** | 白名单严格反模式防御生效 |
| **C11** | **D3 某步所有动作** $IG=0$ | **单步得分赋值 1.0** | **单步优势量赋值 0.0** | <font color=red>**YES**</font> | **单步标准化公式与优势量公式在分子为 0 时有定义冲突** |
| **C12** | D3 仅 1 个动作 $IG>0$ | 该动作计入最优动作集 | 该动作计入最优动作集 | **NO** | 最大值集合定义闭合 |
| **C13** | D3 更新后某假说后验概率 | 贝叶斯项分子为 0，该项 | 贝叶斯项分子为 0，该项 | **NO** | 测度为零项按连续极限处理记 0 |
| **C14** | D3 先验出现零概率 | 形式化移除一直记 | 形式化移除一直记 | **NO** | 状态机过滤规则跟踪 |
| **C15** | D6 策略分歧率 $D=0.0$ | Bootstrap 样本全为 0, CI=[0, 0] | Bootstrap 样本全为 0, CI=[0, 0] | **NO** | 单侧非劣性判定必然 PASS |
| **C16** | D6 策略分歧率 $D=1.0$ | Bootstrap 样本全为 1, CI=[1, 1] | Bootstrap 样本全为 1, CI=[1, 1] | **NO** | 单侧非劣性判定必然 FAIL |

| | | | | | |
|---|---|---|---|---|---|
| **C17** | **D6 分位数落在非** | **采用线性插值** | **采用最近邻离散取** | <font color=red>**YES**</ | **规范未指定 Hyndman-** |
| **C18** | 模型连续输出非法格式达 4 步 | 故障率 4 / 30 > 10 % 4/30>10 % | 故障率 4 / 30 > 10 % 4/30>10 % | **NO** | `INCONCLUSIVE_DATA` 触发准则明确 |
| **C19** | Session 因网络挂 | 标记 `PROT` | 标记 `PROT` | **NO** | 错误分类矩阵单射闭合 |
| **C2** | 同一 | 输出哈希 | 输出哈希 | **NO** | 分层确定性伪 |

| | |
|---|---|
| mid-2 | |
| mid-2 | |
| mid-2 | |
| 0 | |
| 0 | |
| 22 | |
| 22 | |
| 30 | |

30

- $\Delta$ –
- D1
-
- $N$ 1
-
- $k$=1 $N$
-
- D1 ($k$)
-
- 0
-
- D1
-
- 1
-
- D1
-
- prereg
-
- threshold
-
- CR
- base
-

| |
|---|
| • $N$<br>1 |
| • |
| • $k$=1<br>$N$ |
| • |
| • 12<br>1 |
| • |
| • $m$=1<br>2 |
| • |
| • $a$∈A |
| • |
| • 0 |
| • |
| • $m$ |
| • |
| • $k$ |
| • |
| • ($k$) |
| *1*.<br>$t$ |
| 4 |

| |
|---|
| 1. ma xIG( a 2. ′ 3. ) IG( a 4. t 6. 7. ) |
| 14 |
| *1*. *t* |
| 19 |
| *1*. *t* |
| 23 |
| • equiv |
| • |
| mid-2 |
| |
| • 1 |
| • |
| • 2 |
| • |
| • 3 |
| • |
| 1. 1 |
| 4 |
| 1. 2 |
| 8 |
| 1. 3 |
| 12 |

| |
|---|
| 1.2 |
| 17 |
| 1.1 |
| 21 |
| 1.0 |
| 25 |
| • mid |
| • |

# PHASE 10 — 最终可实现性判定结论 (FINAL VERDICT)

code Code

```
================================================================================

SUB-SYSTEM VERIFICATION STATUS:
--------------------------------
```

| | | | | | |
|---|---|---|---|---|---|
| 1.′ | | | | | |
| *I*.*t* | . | | | | |
| 1 | | | | | |

| BL OC | CURREN T_DEFINI | COUNT EREXA | WHY_I T_PRE | MINIMAL_ FIX | STATUS |
|---|---|---|---|---|---|
| **BL OC K-1 1** | H mid-2 *H* mid-2 规则集未定义冲突仲裁规则与规范化化简 | 场景 C3：输入同时满足两条规则，输出不同状态 | 工程师 A 按字典序决断，工程师 B 按列表短路决断，输出发散 | 强制 AST 规范化排序，多规则冲突时以固定字典序 min ( RuleID ) | <font color=red >**OPEN**</ font> |
| **BL OC K-1 2** | D3 统计指标公式在效率比与优势量之间自相矛盾 | 场景 C11：所有动作 I G = 0 *IG*=0 时，公式 A 得 1.0，公式 B 得 0.0 | 零假设置换分布方差被彻底改变，判定结果不可复现 | 彻底废除比值公式，唯一锁定为绝对优势量差值 Δ = I G ( a t ) − I G - Δ=*IG*(*a* | <font color=red >**OPEN**</ font> |

| | | | | | |
|---|---|---|---|---|---|
| **BLOCK-13** | D6 未锁定离散分位数计算插值算法（Quantile | 场景 C17：Bootstrap 样本分位数落在 | 工程师 A 调 NumPy 线性插值（下 | 显式锁定为 Hyndman-Fan Type 7 分位数计算标准，给出 | <font color=red>**OPEN**</font> |
| **BLOCK-14** | A* 算法缺少启发式代价平局出队规则 | $H_{\text{mid-3}}$ / $H_{\text{mid-3}}$ 搜索两个相同长度 | 候选程序合成结果不确定，导致基准模型输出漂 | 优先队列强制加入二级比较键：`Key = (Cost, CanonicalString(AST))` | <font color=red>**OPEN**</font> |

| |
|---|
| mid-2 |
| |

| |
|---|
| $t$ |
| |
| $IG$ |

| |
|---|
| mid-3 |
| |

| |
|---|
| 1. mid-2 |
| 4 |
| mid-2 |
| |
| mid-2 |
| |
| ◦ 1 |
| ◦ |
| ◦ $n$ |
| ◦ |
| ▪ 1 |
| ▪ |

| |
|---|
| 1. target |
| 7 |
| *i* |
| |
| *j* |
| |
| *i* |
| |
| *j* |
| |
| 1 |
| |
| *m* |
| |
| *M* |
| (1) |
| |
| (2) |
| |
| (*k*) |
| |
| *1*. *M* |
| *1*. *M* |
| *1*. *M* |
| *M* |
| 1. 0 |
| 4 |
| *1*. *t*+1 |
| 9 |
| *1*. *t* |
| 13 |
| 14 |

16

*1*.*t*

20

*1*.*t*+1

24

*1*.*t*

29

1. 0

33

D3

D3

*t*

*t*

*t*

|A

*t*

|

1

*a*∈A

*t*

∑

*t*

D3

(*k*)

| |
|---|
| $T$<br>D3<br><br><br><br>1 |
| |
| $t$=0<br>$\sum$<br>$T$<br>D3<br><br>−1 |
| |
| $t$ |
| |
| • 1 |
| • |
| • 2 |
| • |
| • 3 |
| • |
| • 0 |
| • |
| • $t$+1 |
| • |
| • $i$ |
| • |

$$\sum_{j=1}^{3} \pi_t(M_j) \cdot \mathrm{I}[M_j(z_t, a_t) = y]$$

$$\pi_t(M_i) \cdot \mathrm{I}[M_i(z_t, a_t) = y]$$

- $j=1$
  3
- 
- $t$
- 
- $j$
- 
- $j$
- 
- $t$
- 
- $t$
- 
- $t$
- 
- $i$
- 
- $\tau$
- 
- $i$
- 
- $t$

$$\sum_{i=1}^{3}$$

$t$

$i$

$i$

| |
|---|
| $t$ |
| |
| $\sum_{i=1}^{3}$ |
| |
| $i$ |
| |
| $2$ |
| |
| $i$ |
| |
| $2$ |
| |
| $t$ |
| |
| $t$ |
| |
| $\sum_{y \in S}$ |
| |
| $t$ |
| |
| $t+1$<br>$y$ |
| |
| • $a \in A$<br>• $t$<br>•<br>• • |
| • |
| • $t$ |
| • |
| • $t$ |
| • |

- *t*
-
- *t*
-
- |A
- *t*
-
- |

1

-
- 0
-
- D3
-
- 1
-
- D3
-
- D3
  (1)
-
- D3
  (*N*)
-
- wilcoxon
-
- *N*

1

-
- *k*=1

$\sum_{N}$

•

• D3
(*k*)

•

(1)

(*N*)

4

$\bar{D}$

(1)
*

$\bar{D}$

(2)
*

$\bar{D}$

(*B*)
*

0.99

• equiv

•

• 0.99

•

mid-3

mid-3

# 六、FINAL VERDICT (终审裁决)

code
Code

```
============================
============================
========================
                    SUB-
SYSTEM VERIFICATION STATUS:
----------------------------
----------------------------
------------------------
  BLOCK-11 (Hmid-2
Canonicalization &
Conflict):    CLOSED
  BLOCK-12 (D3 IGA
Mathematical Operator):
CLOSED
  BLOCK-13 (D6 Hyndman-Fan
Type 7 Quantile):
CLOSED
  BLOCK-14 (Hmid-3 A*
Heuristic Specification):
OPEN

----------------------------
----------------------------
------------------------
  RUNTIME_ABI_STATUS:
CLOSED
  EVALUATION_ABI_STATUS:
CLOSED
  STATISTICAL_ABI_STATUS:
CLOSED

IDENTIFIABILITY_ABI_STATUS:
CLOSED
  DETERMINISM_STATUS:
OPEN  (受阻于 BLOCK-14 缺失的启
发式函数定义)
============================
============================
```

*t*

*t*

D
3

D
3

- *j*=
  1
  3
- •
- *t*
- •
- *j*
- •
- *j*
- •
- *t*
- •
- *t*
- •
- *t*
- •
- *i*
- •
- *i*
- •
- *t*

| 用例 | 输入条件与场景 | 规范期望行为 | 独立实现一致性 | 闭合结论 |
| --- | --- | --- | --- | --- |
| **C3** | $H_{\text{mid-2}}$ = $H_{\text{mid-2}}$，规则集内多条规则同时匹配 | 按 min CanonString 选定最终 minCanonString | 两工程师均输出字典序最小规则的 target | **CLOSED** |
| **C4** | $H_{\text{mid-2}}$ = $H_{\text{mid-2}}$，出现逻辑等价但书写不同的 | `CanonRule` 将其重写为同一 `CanonString` 并去重 | 初始版本空间基数严格锁定，无重复项 | **CLOSED** |

| | | | | |
|---|---|---|---|---|
| C11 | D3 步长内所有候选动作的 $IG(a)=0$ | 单步优势量严格计算为 $d_t = 0 - 0 = 0.0$ $d_t$ | 统计量计算完全一致，无除零风险 | CLOSED |
| C17 | D6 分位数落在非整数索引点（ $9900.01$ | 严格按 Type 7 算子执行 $0.01$ $0.01$ | 浮点数截断到双精度一致，无插值分歧 | CLOSED |
| C21 | 规则内两 AND 条件颠倒：`K == L AND X == A` | 强制按 $X \prec K \prec \mathrm{act}$ 排序重写 | 序列化字符串 100% 相同 | CLOSED |
| C2 | `act IN {c,` | 集合元素字典序 | 序列化字符 | CLOSED |
| C23 | 模型集合包含完全相同的冗余子句 | 集合操作执行规范化去重，只保留 1 项 | 规则数 $m$ 准确计算， | CLOSED |
| C2 | 两个互斥假说 | 取 `CanonString` | 输出单一确 | CLOSED |

| | | | | |
|---|---|---|---|---|
| **C25** | D3 全周期无信息增益（所有 step $IG=0$） | 全场 $\Delta_{D3}=0.0$，$\Delta_{D3}=0.0$，Wilcoxon 无法拒绝零假设 | 最终 D3 严格下达 `FAILED` | **CLOSED** |
| **C26** | D3 步长仅 1 个动作 $IG>0$，其余为 0 | 准确计算平均值，选优动作获得正增益 $d_t>0$ | 累加标量完全对齐 | **CLOSED** |
| **C27** | 观测导致三模型全部不兼容（信息增益为 0） | 抛出 `INVALID_REFERENCE_OUTCOM` | 状态机安全受控熔断，无脏数据 | **CLOSED** |

| | | | | |
|---|---|---|---|---|
| **C28** | D6 分位数样本落在两相异点之间 | $Q_{0.99}=x(9900)+0.01(x(9901)-x(9900))$ $Q_{0.99}=x_{(9900)}+0.01(x_{(9901)}-x_{(9900)})$ | 数值解析完全重合 | **CLOSED** |

| | | | | |
|---|---|---|---|---|
| **C29** | D6 所有 Bootstrap 样本值全等（方差为 0） | 插值项为 0，直接返回 $Q_{0.99} = x_{(1)}$ $Q_{0.99}$ | 极值边界平滑覆盖 | **CLOSED** |
| **C30** | $H_{\text{mid-3}}$ $H_{\text{mid-3}}$ **两个节点 Cost 完全相同** | **由于** $h(n)$ **根本未定义，无法计算** $f(n) = g(n) + h(n)$ | **算法在两工程师手中根本无法启动编译** | <font color=red >**OPEN**</font> |

mid-2

mid-2

*t*

D3

*t*

0.99

(9900)

(9901)

(9900)

0.99

(1)

mid-3

- mid-3
-
- mid-3
-

mid-3

| | |
|---|---|
| | |
| • mid-3 | |
| • | |
| • * | |
| mid-3 | |
| | |
| mid-3 | |
| | |
| *H*mid-3 | |
| | |
| train | |
| | |
| DSL | |
| | |
| • train | |
| • | |
| • $\tau$ | |
| • | |
| • $\tau$ | |
| • | |
| • $\tau$ | |
| • | |
| • $\tau$+1 | |
| • | |
| • $\tau$=0 20 | |
| • | |
| • * | |
| • fallback | |
| • | |
| partial | |

| |
|---|
| • partial |
| • |
| 1. partial |
| 4 |
| * |
| 1. * |
| 1. train |
| 8 |
| *1*. $\tau$ |
| 12 |
| *1*. $\tau$+1 |
| 16 |
| 1. train |
| 20 |
| 1. * |
| *1*. $\tau$ |
| 26 |
| *1*. $\tau$+1 |
| 30 |
| • fallback |
| • |

# STEP 10 — $H_{mid-3}$

## 形式化实现契约全览

code Text

```
Hmid3 Specification Contract:

Algorithm = Deterministic Uniform-
```

| 用例 | 输入条件与场景 | 规范期望行为 (Normative Result) | 独立可重现 | 闭合 |
| --- | --- | --- | --- | --- |
| C31 | 两个候选 AST 的节点数 $g$ $g$ 相同 | 按 `CanonString` 的 ASCII 字典序排序，较小者优先出队 | 100% 确定 | CLOSED |
| C32 | 两个候选 AST 的 | 字典序严格全序仲裁，不存在两个最 | 100% 确 | CLOS |
| C33 | 两个分支推导出 | 第二个分支命 | 100% 确 | CLOS |
| C34 | 多个完整 AST 同时满足 100% 训 | 队列最先出队者（节点数最少、字典序最小）直接作为最终解决方案退出 | 100% 确定 | CLOSED |
| C35 | 某个候选 AST 节点数恰好为 12 | 允许作为完整程序被评估；若内容完整则终止扩展其子节 | 100% 确 | CLOS |
| C36 | 某个产生式尝试生成第 13 个节点 | $g = 13 > 12$ $g=13>12$ ，在入队前直接剪枝丢弃 | 100% 确定 | CLOSED |
| C37 | 搜索前序遍历中出现多个等价的 | 最左推导规则唯一锁定仅展开第一个非终结符 | 100% 确 | CLOS |
| C38 | 搜索展开节点数累加至第 1000 个 | 计数器触发饱和截断，搜索终止，输出 $P_{\text{fallback}}$ | 100% 确定 | CLOSED |
| C39 | 训练集包含逻辑矛盾数据（无解） | 遍历完 1000 节点无解，确定性输出 $P_{\text{fallback}}$ | 100% 确定 | CLOSED |
| C40 | 跨平台运行（Linux ARM64 vs Windows | 离散节点展开计数与字符串比较完全脱敏于浮点和时钟，输出 PL 级全等 | 100% 确 | CLOSED |

fallback

fallback

mid-3

mid-3

mid-3

- *t*
-
- *t*
-
- *t*
-
- IA
- *t*
-
- I

1

-
- *a*
-
- *t*
-
- D3
-
- 4
- 0.99
-

- equiv
-
- 7
- 6

1. mid-3

5

- ref
- 1
- 2
- 3
- *t*
- 0
- *t*+1 *y*
- *t*
- *t*
- *t*
- *t*

- o
- o lA
  - *t*
  - o
  - o l 1
    - o
- o *a*
- o
- o *t*
- o
- o corrupt
- o
- o forward
- o
- o debias
- o
- o 4
- o 0.99
- o
- o *k*
- o
1. mid-2

| |
|---|
| 5 |
| 1. mid-3 |
| 9 |
| • mid |
| • |
| 1. mid-1 |
| 4 |
| 1. mid-4 |
| 8 |
| 1. mid-5 |
| 12 |
| 1. mid-6 |
| 16 |

# C. D0–D6 评测端点有效性矩阵 (Endpoint Validity Matrix)

| 维度 | 预注册目标 | 实际实现度量 | 理论 |
| --- | --- | --- | --- |

| 规范组件 | 规范中是 | 第三方能 | 状态定性 | 阻塞原因说明 |
| --- | --- | --- | --- | --- |
| **PRNG 派** | 是 | 是 | **IMPLEM** | 64 位移位异或算 |
| **Layer A** | 是 | 是 | **IMPLEM** | 离散状态数组与 |
| **Proj 视界投影** | 是 | 是 | **IMPLEMENTABLE** | 显式丢弃未观测参数 $u_t$ |
| **Hmid-2 (VersionSpace)** | 是 (锁定 333 基数) | 是 | **IMPLEMENTABLE** | 规则 AST 与优先级 $\min(\text{Canon})$ |
| **Hmid-3 (UCS** | 是 (锁定 | 是 | **IMPLEM** | UCS 节点遍历与 |
| **Hmid-1 (CART** | 否 | 否 | **BLOCKED_BY_S** | 缺失节点最优分 |
| **Hmid-4 (ESM-N** | 否 | 否 | **BLOCKED_BY_S** | 缺失阶数历史滑 |
| **Hmid-5 (k-NN** | 否 | 否 | **BLOCKED_BY_S** | 缺失编辑距离度 |
| **Hmid-6 (Ensembl** | 否 | 否 | **BLOCKED_BY_S** | 依赖前述未闭合 |

| 维 | 预注册目标 | 实际实现度量 | 理论与代码是 | 状态定性 |
| --- | --- | --- | --- | --- |
| D 0 | 运行时不变 | 非法 Action 标 | 存在修辞夸大 | **PARTIAL** |
| D 1 | 离散规则时序前向拟合 | 测试集 9 步命中率差值 $\Delta_{D1}$ | 一致（批处理上下文冻结） | **STATISTICAL-CLOSED** |
| D 2 | 多假说前向执行一致性 | 12 格矩阵比对 $CR_{forward}$ $CR$ | 一致（仅限于玩具参考模型） | **PARTIAL** |
| D 3 | 香农信息增益优势量 | 会话级 $d_t$ $d_t$ 均值优势量 | 算子一致，多会话调度未整合 | **STATISTICAL-CLOSED** |
| D 4 | 上下文结构因果泛化 | 替换为 $M$ $M$ 后的准确率 | **完全不一致 (见模块 G)** | **ENDPOINT-INVALID** |
| D 5 | 假设分支前向回溯推导 | $t=10$ $t=10$ 单步虚拟动作 | 一致（独立 Oracle 生成） | **TESTED** |
| D 6 | 跨符号置换策略不变性 | 单侧 Bootstrap Type 7 $Q_{0.99}$ $Q$ | 算子一致，全场采样需自动化 | **STATISTICAL-CLOSED** |

| D 1 | |
| --- | --- |

forward

*t*

0.99

*1.t*

4

*1.t*

8

*1.y*

12

*1.t*

16

*1.t+1y*

20

1.2

24

*1.t*

28

1.D3(*k*)

33

*1.T*1

37

*1*. *t*= 0 20

41

*1*. *t*

45

**F.** $H_{mid-1\ldots6}$ $H_{mid-1\ldots6}$ **参考模型规范可用性**

| 闭合层级 | 规范技术要求 | 当前代码实际达成状态 | 审 |
| --- | --- | --- | --- |
| **1. 符号双射置换** | 建立 $S$, $X$, $K$, $A$ $S,X,K,A$ 独立单射与逆映射 | `D6_BIJECTION_MAP` 与 `D6_INVERSE_MAP` 严格对称 | **CLOSED** |
| **2. 载荷深** | 递归重写输入，消 | `_apply_bijective_perm` | **CL** |
| **3. 预测逆** | 将置换预测还原到 | `perm_d1_preds` 经由逆字 | **CL** |

| | | | |
|---|---|---|---|
| **4. 单会话汉明分歧** | $D(k) = \frac{1}{9}\sum I(\hat{y} \neq \hat{y}_{perm})$<br>$D(k) = \frac{9}{1}\sum I(\hat{y} \stackrel{?}{=} \hat{y}_{perm})$ | 9 个测试点严格计算汉明不一致率 | **CLOSED** |

| | | | |
|---|---|---|---|
| **5. 会话级 Bootstrap** | 以 Session 为独立采样单元重抽 $B = 10^4$ | `evaluate_d6_bootstrap` 实现纯标准库非参数重抽 | **CLOSED** |

| | | | |
|---|---|---|---|
| **6. Type 7 分位数闭式** | h = 1 + ( B − 1 ) p<br>$h=1+(B-1)p$<br>，严格线性插值 | 严格实现<br>Q 0.99 = x ( j ) + g ( x ( j + 1 ) − x ( j ) )<br>$Q_{0.99}=x_{(j)}+g(x_{(j+1)}-x_{(j)})$ | **CLOSED** |

| | | | |
|---|---|---|---|
| **7. 研究级门禁集成** | 100 会话均值置信区间 < 0.10 | 缺少收集 100 会话并自动调用的顶层脚本 | **PARTIAL** |

(*k*)

9

1

$\hat{y}$

$\hat{y}$

perm

4

0.99

(*j*)

(*j*+1)

(*j*)

mid-1 … 6

**裁决**：第三方工程师**仅凭 v1.0.3 绝对无法构建出行为一致的**

$H_{\text{mid-1}}$, $H_{\text{mid-4}}$, $H_{\text{mid-5}}$, $H_{\text{mid-6}}$ $H_{\text{mid-1}}$, $H_{\text{mid-4}}$, $H_{\text{mid-5}}$, $H_{\text{mid-6}}$

。任何私自补充实现的算法均属于未经授权的“自定义模型”。

| 模型 | 理论模型类别 | v1.0.3 规范中是否存在 | 是否锁定超参数与不同规则 | 状态定性 |
| --- | --- | --- | --- | --- |
| Hmid-1 | 贪心条件决策树 (CART) | 否（仅有一句话描述） | 否（未定义相同基尼增益时的特征选取顺序） | **BLOCKED_BY_SPEC** |
| Hmid-2 | 版本空间消除器 (Version Space) | **是 (BLOCK-11 闭合)** | **是 (锁定 333 空间与字典序仲裁)** | **CLOSED** |
| Hmid-3 | 符号程序合成器 (UCS AST) | **是 (BLOCK-14 闭合)** | **是 (锁定 1000 节点展开与 EBNF)** | **CLOSED** |
| Hmid-4 | 二阶有限状态机 (FSM) | 否 | 否（未定义平滑超参数与状态转移矩阵初始分布） | **BLOCKED_BY_SPEC** |
| Hmid-5 | 局部启发式检索器 (k-NN) | 否 | 否（未定义离散符号编辑距离权重） | **BLOCKED_BY_SPEC** |
| Hmid-6 | 集成投票模型 (Ensemble) | 否 | 否（依赖 1/4/5 的闭合） | **BLOCKED_BY_SPEC** |

| mid-1 | |
| --- | --- |
| | |

| mid-2 | |
| --- | --- |
| | |

| mid-3 | |
| --- | --- |
| | |

| mid-4 | |
| --- | --- |
| | |

| mid-5 | |
| --- | --- |
| | |

| | |
|---|---|
| mid-6 | |
| | |
| mid-1 | |
| | |
| mid-4 | |
| | |
| mid-5 | |
| | |
| mid-6 | |
| | |

## I. 当前真正有效的声称(Claims That Are Currently Valid)

1.

| 用例 ID | 样本输入差值向量 $\vec{d}$ ( $N=10$ ) | 预期秩和统计量 $W^+$ | 预期渐近 $p$ 值特征 | 检验判定目标 |
|---|---|---|---|---|
| TC-01 (全正向) | `[0.1, 0.2, 0.3, 0.4, 0.5, 0.6, 0.7, 0.8, 0.9, 1.0]` | 55.0 | $p < 0.005$ | 极显著拒绝零假设 |
| TC-02 (全负向) | `[-0.1, -0.2, -0.3, -0.4, -0.5, -0.6, -0.7, -0.8, -0.9, -1.0]` | 0.0 | $p > 0.999$ | 强力接受零假设 |
| TC-03 (全零值) | `[0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0]` | 0.0 | $p = 1.000$ | 统计量无方差退化 |
| TC-04 (对称正负) | `[-0.5, -0.4, -0.3, -0.2, -0.1, 0.1, 0.2, 0.3, 0.4, 0.5]` | 27.5 | $p \approx 0.500$ | 严格无偏对称 |
| TC-05 (大量并列结) | `[0.2, 0.2, 0.2, 0.2, -0.2, -0.2, -0.2, -0.2, 0.5, -0.5]` | 27.5 | $p \approx 0.500$ | 平均结秩计算对齐 |

| | | | | |
|---|---|---|---|---|
| **TC-06 (零值主导)** | `[0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.1, 0.2]` | 19.0<br>19.0 | p ≈ 0.05 ~ 0.10<br>$p \approx 0.0$ | Pratt 零值秩保留核验 |
| **TC-07 (单极端正值)** | `[0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 10.0]` | 10.0<br>10.0 | p > 0.05<br>$p > 0.0$ | 单点无法产生显著性 |
| **TC-08 (微弱正偏态)** | `[0.01, 0.01, 0.01, -0.01, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0]` | 6.0<br>6.0 | p > 0.10<br>$p > 0.1$ | 小样本低方差稳健性 |

$d$

+

| |
|---|
| 1. mid-3 |
| 5 |
| 1. mid-1 |
| 5 |
| 1. mid-4 |
| 9 |
| 1. mid-5 |
| 13 |
| 1. mid-6 |
| 17 |
| 1. mid |
| 5 |
| 1. mid-1 |

| |
|---|
| 9 |
| 1. mid-4 |
| 13 |
| 1. mid-3 |
| 6 |
| 1. mid-2 |
| 11 |
| mid-2 |
| |
| mid-3 |
| |